



UNIVERSIDADE ESTADUAL DE CAMPINAS

Faculdade de Engenharia Mecânica

FÁBIO DE SOUZA MORAES MORI

**Rede neural profunda para estimar o SOC da
bateria através de KPIs aplicados em Motorsport**

Campinas

2022

FÁBIO DE SOUZA MORAES MORI

Rede neural profunda para estimar o SOC da bateria através de KPIs aplicados em Motorsport

Documento apresentado à Faculdade de Engenharia Mecânica da Universidade Estadual de Campinas para o Exame de Qualificação de Mestrado em Engenharia Mecânica.

Orientador: Prof. Dr. Janito Vaqueiro Ferreira

Campinas

2022

RESUMO

O desenvolvimento de tecnologias em veículos elétricos vem crescendo no mundo de *Motorsports*, onde cada vez mais as categorias elétricas tem tido prestígio e ganham importância para servir como base no desenvolvimento de tecnologias e soluções que serão utilizadas nos veículos elétricos comerciais nas ruas. A bateria de Íons de Lítio é a principal fonte de energia para estes veículos e o controle e gerenciamento de seus parâmetros é alvo de constante pesquisa e aprimoramento. Uma previsão correta do Estado de Carga (*SOC -State of Charge*) de uma célula é fator crucial para que se possa extrair o maior desempenho possível do conjunto de baterias e utilizar toda sua autonomia. Em *Motorsports*, ter uma previsão correta deste parâmetro é fundamental para a definição de estratégia de corrida entre piloto e equipe, e pode ser a chave para se obter a vitória.

O enfoque deste trabalho está na inclusão de Indicadores de Performance (*Key Performance Indicators - KPI*) de pilotagem em um modelo de uma Rede Neural Artificial (RNA) para aprimorar o valor estimado do SOC de uma célula de bateria, que é calculado através de um Filtro de Kalman Sigma Ponto (*Sigma-Point Kalman Filter - SPKF*) baseado nas equações de estado de um modelo de circuito equivalente (*Enhanced Self-Correcting - ESC*) de uma Bateria de Lítio. As características que definem o condutor influem diretamente na curva de descarga do SOC e são mais evidenciadas no mundo do automobilismo profissional, onde observamos diferenças muito maiores em comparação ao condutor comum. Adicionar o KPI ao modelo de previsão através de uma RNA objetiva melhorar a precisão dos dados e consequentemente a performance da utilização do sistema de baterias. Uma melhora neste cálculo trará benefícios relacionados a autonomia e otimização do conjunto de baterias, que são dois dos fatores que mais geram entraves no desenvolvimento da tecnologia de propulsão elétrica nos automóveis atualmente.

Os resultados apontaram que o modelo híbrido desenvolvido possui ótima precisão, superando o SPKF em algumas situações. O estudo indica que este método poderá obter resultados precisos e adaptáveis as diferentes características observadas quando aplicados em *Motorsports*, onde a diferença das características de pilotagem está imposta como valores de entrada do sistema, diferentemente dos outros modelos já existentes.

Palavras-chave: Motorsports, Estado de Carga, Rede Neural Artificial, Aprendizagem Profunda, Filtro de Kalman Sigma Ponto, Circuito Equivalente.

ABSTRACT

The development of new technologies about electric vehicles is growing up in the Motorsports, where new electrics car categories have been importance as a development basis and innovation will be used on the streets. Lithium Ion Battery is the most important power supply for electric vehicles and your management and control is constant research target. A correct estimation of Cell State of Charge is primordial to extract the highest performance of a battery pack and utilize all your capacity. In Motorsports this correct estimation is fundamental to define the strategy race between the driver and the engineer and may be the key to victory.

This work includes the driver Key Performance Indicator (KPI) into a Artificial Neural Network (ANN) model to improve the State of Charge (SOC) estimated by Sigma-Point Kalman Filter (SPKF) based on state equations of Enhanced Self-Correcting (ESC) model of Lithium Ion Battery. The driver characteristics has direct influence on discharge curve of SOC and this is most important and significant with professionals' drivers, compared to ordinary conductors. The SOC estimate model with KPI and ANN help to improve the accuracy and performance about the system. The better estimate will bring advantages in the use of autonomy and optimization of the battery pack, the two factors that need to be improved with new technologies.

This document presents all the development and what can be explored in future works. The work has divided into 3 parts, the first calculates the ESC model parameters of Lithium Ion Cell Battery with the Low Current Open Circuit Voltage and Dynamic Urban Dynamometer Driving Schedule battery laboratory dataset. Then the Sigma-Point Kalman Filter estimates the State of Charge value and the final step extracts the KPIs from the (*Urban Dynamometer Driving Schedule* – UDDS) discharge current profile and input this value with the SOC estimated by SPKF into a ANN to get a new estimated value, with greater precision.

The results showed that the hybrid model has great precision, surpassing the only the SPKF estimated in some situations. This study indicates that this method can get accurate and adaptable results in Motorsports applications, where the drivers characteristics are input data from the modeling system.

Keywords: Motorsports, State of Charge, Artificial Neural Network, Deep Learning, Sigma-Point Kalman Filter, Enhanced Self-Correcting Model.

LISTA DE ILUSTRAÇÕES

Figura 1.1 – Figura extraída do artigo Saxena <i>et al.</i> 2012	15
Figura 1.2 – Figura extraída do artigo Xing <i>et al.</i> 2014	23
Figura 1.3 – Figura extraída do artigo Guo <i>et al.</i> 2019	23
Figura 1.4 – Figura extraída do artigo Hannan <i>et al.</i> 2018	25
Figura 1.5 – Figura extraída do artigo He <i>et al.</i> 2018	27
Figura 1.6 – Figura extraída do artigo Kharazmi <i>et al.</i> 2019	29
Figura 1.7 – Figura extraída do artigo He <i>et al.</i> 2014	30
Figura 2.1 – Fluxograma Geral - Incluindo relação OCV-SOC	35
Figura 2.2 – Fluxograma Geral - Incluindo Modelo A123	36
Figura 2.3 – Fluxograma Geral - Incluindo SPKF	38
Figura 2.4 – Fluxograma Geral - Incluindo KPI	40
Figura 2.5 – Sinal de Corrente do perfil UDDS	40
Figura 2.6 – Sinais de Freio e Acelerador do perfil UDDS	41
Figura 2.7 – Velocidade do Freio	42
Figura 2.8 – Liberação do Freio	42
Figura 2.9 – Agressividade do Freio	43
Figura 2.10–KPI do Freio	43
Figura 2.11–Velocidade do Acelerador	45
Figura 2.12–Liberação do Acelerador	45
Figura 2.13–Agressividade do Acelerador	46
Figura 2.14–KPI do Acelerador	46
Figura 2.15–Fluxograma Geral Final	47
Figura 3.1 – Tensão [V] nos passos 1 e 2 para todas as temperaturas.	48
Figura 3.2 – OCV - A123 à 35°C	49
Figura 3.3 – OCV - A123 à 35°C	49
Figura 3.4 – DYN - A123 à 35°C	50
Figura 3.5 – DYN - A123 à 35°C	51
Figura 3.6 – Estimativa SOC SPKF	52
Figura 3.7 – Erro SPKF	53

Figura 3.8 – Estimativa SOC SPKF < 50%	53
Figura 3.9 – Resultado da estimativa do SOC pelos modelos	55
Figura 3.10–Resultado da estimativa dos modelos com SOC menor que 50%	56
Figura 3.11–Resultado da estimativa dos modelos com SOC menor que 20%	57
Figura 3.12–Sinal UDDS	58
Figura 3.13–Sinal FUDS	58
Figura 3.14–Resultado Rede Neural Perfil FUDS - 35°C	59
Figura 3.15–Sinal FUDS - KPI de freio	60
Figura 3.16–Sinal FUDS - KPI do acelerador	60
Figura 3.17–Função de perda para o sinal FUDS à 35°C	61
Figura 3.18–Sinal FUDS - KPI de freio com média móvel	61
Figura 3.19–Sinal FUDS - KPI do acelerador com média móvel	62
Figura 3.20–Resultado da RNA com perfil FUDS e KPI com média móvel à 35°C	62
Figura 3.21–Função de perda para o sinal FUDS e KPI com média móvel à 35°C	63
Figura 5.1 – Fórmula E temporada 2019 - 2020	67

LISTA DE TABELAS

Tabela 3.1 – Configuração Rede Neural	55
Tabela 3.2 – Configuração Rede Neural	59

LISTA DE ABREVIATURAS E SIGLAS

ANFIS	Adaptative Neural Fuzzy Inference System
BMS	Battery Management System
BPNN	Back Propagation Neural Network
BSA	Backtracking Search Algorithm
CALCE	Center for Advanced Life Cycle Engineering
DST	Dynamic Stress Test
DYN	Dynamic Urban Dynamometer Driving Schedule
ECM	Equivalent Circuit Model
EKF	Extended Kalman Filter
ELU	Exponential Linear Unit
EM	Electrochemical Model
EODV	End of Discharge Voltage
EODV	End of Discharge Voltage
ESC	Enhanced Self-Correcting)
FK	Filtro de Kalman
FP	Filtro de Partículas
FUDS	Federal Urban Driving Schedule
HIL	Hardware-in-the-Loop
HPPC	Hybrid Pulse Power Characterisct
KPI	Key Performance Indicador
LS	Least Square

MAEE	Maximum Absolute Estimated Error
NASA	National Aeronautics and Space Administration
OCV	Open Circuit Voltage
P2D	Pseudo-Two-Dimensional
PDE	Partial Differential Equation
PINNs	Physics Informed Neural Networks
RMSE	Root Mean Square Error
RNA	Rede Neural Artificial
RUL	Remaining Usefull Life
SOC	Estado de Carga
SOE	State of Energy
SOH	State of Health
SPKF	Sigma Point Kalman Filter
UDDS	Urban Dynamometer Driving Schedule
UKF	Unscented Kalman Filter
VPINN	Variational Physics Informed Neural Network

LISTA DE SÍMBOLOS

η	Eficiência de Coulomb
DoD	Percentagem de carga retirada da bateria durante a descarga
R_p	Resistência em paralelo
C_p	Capacitância em paralelo
R_0	Resistência Ôhmica
rp	Raio da partícula
L_{pos}	Espessura do eletrodo
ϵ	Fração de volume do material ativo
Q	Capacidade total da célula
i	Corrente
v	Tensão
z	Estado de carga
V_{ajus}	Tensão ajustada
T	Temperatura
i_R	Equação de estado do algoritmo de teste dinâmico
s	Equação de estado do algoritmo de teste dinâmico
h	Equação de estado do algoritmo de teste dinâmico
rms	Raiz do erro quadrático médio
γ	Parâmetro de histerese do modelo de circuito equivalente da bateria
M	Parâmetro de histerese do modelo de circuito equivalente da bateria
M_0	Parâmetro de histerese do modelo de circuito equivalente da bateria

X_0	Incerteza do estado inicial do SPKF
V	Sensor de tensão na equação de saída do SPKF
W	Sensor de corrente na equação de estado do SPKF
N_x	Elementos do vetor de estado do SPKF
N_x	Elementos do vetor de medição do SPKF
N_u	Elementos do vetor de entrada do SPKF
N_w	Ruído do processo do sistema do SPKF
N_w	Ruído do sensor do sistema do SPKF
N_a	Número de elementos no vetor de estado aumentado do SPKF
X_{hat}	Valores de estimativa de estado do SPKF
y_{hat}	Valores de previsão de tensão do SPKF
L	Matriz de ganho do SPKF
ΣXY	Matriz de covariância cruzada do SPKF
ΣY	Matriz de covariância de inovação do SPKF
ΣX	Matriz de covariância de erro do SPKF
X_a	Matriz de estado aumentado do SPKF
h_k	Matriz de histerese do SPKF
r	Medição residual
Δt	Intervalo de tempo
zk_{bnd}	Bordas de erro do SOC definidas na simulação
V_{min}	Tensão mínima
V_{max}	Tensão máxima
$I_{discharged}$	Corrente de descarga da bateria
$I_{charged}$	Corrente de recarga da bateria

SUMÁRIO

1	Introdução	13
1.1	Introdução ao tema	13
1.2	Revisão superficial do Estado da Arte Atual	14
1.3	Desenvolvimentos Propostos	30
1.4	Resumo da Tese	31
2	Metodologia	32
2.1	Teste 1: Tensão de Circuito Aberto	32
2.2	Teste 2: Perfil Dinâmico de Carga e Descarga	33
2.3	Algoritmo da Tensão de Circuito Aberto	34
2.4	Algoritmo do Teste Dinâmico	35
2.5	Filtro de Kalman Ponto Sigma	37
2.6	Indicadores de Performance do Piloto	39
2.6.1	Agressividade e velocidade no pedal de freio	41
2.6.2	Agressividade e velocidade no pedal do acelerador	44
2.7	Rede Neural de Aprendizagem Profunda	44
3	Resultados e Comentários	48
3.1	Teste 1: Tensão de Circuito Aberto	48
3.2	Teste 2: Perfil Dinâmico de Carga e Descarga	50
3.3	Algoritmo da Tensão de Circuito Aberto	51
3.4	Algoritmo do Teste Dinâmico	52
3.5	Filtro de Kalman Ponto Sigma	52
3.6	Rede Neural de Aprendizagem Profunda	54
3.7	Validação da RNA	57
4	Conclusão	64
5	Trabalhos Futuros	65
Referências		68

1 INTRODUÇÃO

A aplicação da inteligência artificial pode ser uma solução inovadora para um melhor desempenho de veículos elétricos em competições automobilísticas. Ao passo que a energia elétrica em veículos favorece o crescimento sustentável em regiões onde a matriz energética também é (já que a geração de energia será necessária para recarregar as baterias), por outro lado, gera um certo obstáculo relacionado ao potencial de velocidade e autonomia dos carros. Avanços recentes nas equações que regem a eletroquímica nas baterias, circuitos elétricos equivalentes mais precisos ou nos algoritmos como Redes Neurais e Filtros de Kalman ainda não foram suficientes em obter com maior precisão o valor de carga existente nas baterias para aplicabilidade a nível de uma competição automobilística. Posto isso, cabe o questionamento, se a tecnologia das baterias de íons de lítio atingiu o seu limite, o que desafia e, de certa forma, pode inclusive ameaçar a categoria da competição em questão, ou se ainda podemos melhorar a estimativa dos algoritmos embarcados através da inclusão de novos parâmetros. Esta é uma pergunta instigante a ser respondida, cuja temática norteia esta dissertação.

1.1 Introdução ao tema

As mudanças climáticas avançam a cada ano e têm sido pauta de discussões entre líderes mundiais e entidades governamentais e não governamentais. Diante dessa problemática atual, a busca pela sustentabilidade deve ser priorizada nos diversos setores e serviços. Montadoras de veículos urbanos estão investindo largamente na produção de veículos movidos a energia elétrica com objetivo de torná-los mais acessíveis e adaptados à sociedade. No contexto do automobilismo, o desenvolvimento de uma categoria 100% elétrica atende a premissa de sustentabilidade no que tange à redução da emissão de gás carbônico (CO_2) na atmosfera. Entretanto, existem desafios para a categoria de carros elétricos do tipo fórmula, um deles é a bateria, em função da sua vida útil limitada e seu posterior descarte, que se ocorrido de forma indevida é nociva ao meio ambiente.

O outro é o desempenho do carro em competições automotivas, pois a autonomia do veículo é definida pela quantidade de carga disponível em uma célula de bateria de lítio e aumentar o número de células dentro de um veículo se torna inviável diante do aumento da massa, volume e custo que seria adicionado ao carro. É por isso, inclusive, que as baterias

utilizadas são de lítio e não de chumbo. Avanços tecnológicos da célula de bateria, bem como o desenvolvimento de redes neurais nos algoritmos de predição de carga, permitiram o uso da bateria próximo ao limite de corrente e tensão e viabilizaram a consolidação dos veículos elétricos e da categoria automobilística em questão. Ainda assim, a potência do veículo pode oscilar, sendo necessária a adoção de uma estratégia onde a carga da bateria seja administrada até o término da prova pelo piloto.

Para mensurar a carga disponível nas células são utilizadas a tensão, em Volts, e a corrente, em Amperes, mas a relação da carga disponível com os valores medidos não é direta e o uso de algoritmos é necessário, sendo assim também o desenvolvimento deles torna o cálculo mais eficiente. O valor de carga disponível em uma célula é denominado SOC e existem diversos algoritmos desenvolvidos para esta aplicação, embora hoje em dia muito mais eficientes, ainda existe margem para erro nesta previsão principalmente nos valores finais.

Portanto, um questionamento acerca da possibilidade de incluir a personificação de cada piloto dentro do algoritmo é uma hipótese a ser testada, afinal, assim como em veículos à combustão, não somente o mapa de injeção define o consumo, mas a performance de cada piloto é fator relevante para prever o real consumo durante o trajeto. O presente trabalho, propôs um modelo híbrido inovador de algoritmo utilizando Filtro de Kalman (FK), um modelo de circuito equivalente (*Equivalent Circuit Model - ECM*) da bateria e RNAs para inclusão dos parâmetros de pilotagem e cálculo do SOC com aplicação em *Motorsport*.

1.2 Revisão superficial do Estado da Arte Atual

Foram pesquisados e estudados trabalhos relacionados ao desenvolvimento de algoritmos para obtenção do valor do SOC de uma célula de bateria. Um dos principais ramos de pesquisa dos trabalhos são aqueles que focam na eletroquímica da célula (*Electrochemical Model - EM*), tentando melhorar o equacionamento que prevê o funcionamento das células através das reações químicas internas que ocorrem durante a sua utilização. Temos também, os trabalhos que concentram sua pesquisa em melhorar o circuito elétrico equivalente que representa estes fenômenos internos e que, de certa forma, replica estas variações para podermos assim calcular o valor do SOC. Por fim, temos as pesquisas que tem como objetivo encontrar o melhor modelo de algoritmo que retorne com maior precisão o cálculo do SOC, independente da forma como ele é calculado, seja por modelos EM ou modelos ECM.

Pela sua importância no desenvolvimento de novas tecnologias, o estudo relacio-

nado a baterias é muito amplo no meio científico. Os algoritmos baseados em dados são mais populares em aplicações embarcadas devido ao seu desempenho relativamente mais rápido em comparação a outros modelos, em teoria mais complexos. [Saxena et al. 2012](#) ressaltam as incertezas inerentes a este sistema mostrando a análise preliminar do desenvolvimento de um algoritmo baseado em dados (ver fluxograma na Figura 1.1) e suas lições aprendidas utilizando um banco de dados, disponibilizado pela *National Aeronautics and Space Administration* (NASA), obtido em laboratório de carga e descarga de células de Íons de Lítio. Os resultados mostraram que os ruídos das medições utilizadas como dados interferem muito na eficácia dos modelos, assim como os transientes de carga e descarga obtidos em laboratórios que podem ser diferentes das aplicações reais do problema e também a extração dos parâmetros da célula, que exige muitas aproximações sensíveis ao resultado encontrado.

[Ning et al. 2016](#), da mesma forma, ressaltam que a variação dos parâmetros internos pode aumentar drasticamente o erro, fazendo uma crítica aos modelos com parâmetros internos estáticos e expondo suas desvantagens, tal como a necessidade de um complexo modelo para obtenção dos parâmetros iniciais que não serão corrigidos durante a aplicação. Sendo assim, propõe a utilização de um modelo de bateria adaptável utilizando um algoritmo de modo deslizante (*Sliding Mode Algorithm*) para reduzir os erros conforme os parâmetros internos da bateria variam. Os resultados foram obtidos através de dados com perfil UDDS e a estimativa do SOC obteve resultados de erro inferiores a 2%.

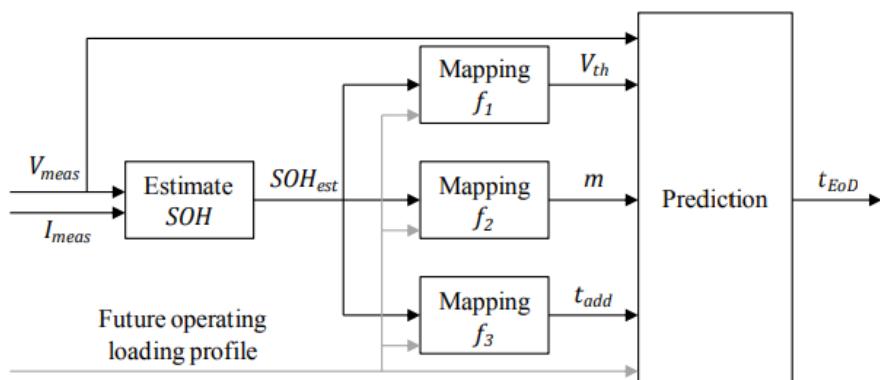


Figura 1.1 – Figura extraída do artigo [Saxena et al. 2012](#)

[Zhang et al. 2014](#) apresentam um trabalho mostrando a degradação dos parâmetros internos envelhecendo uma célula de LiCoO₂ em ciclos com alta temperatura e monitorando seus parâmetros. O mecanismo de degradação foi discutido usando um modelo multi-físico e parâmetros-chave, razões para o enfraquecimento da capacidade e o aumento da resistência

interna foram analisados em detalhes. Todas as evidências indicaram que a reação de formação do filme da interface do eletrólito sólido (*Solid Electrolyte Interface*) é a principal causa de degradação da bateria em alta temperatura ambiente.

Dentre muitos estudos que vão sendo desenvolvidos relacionados a medição de parâmetros de uma célula de Lítio, [Chang 2013](#) discorre que o SOC é um parâmetro muito importante não apenas para sabermos a carga disponível na célula, mas conhecer seu valor exato nos permite melhorar o desempenho, proteger a célula, evitar sobrecargas e também criar estratégias de controle de sua utilização mais racionalmente para conseguir economizar energia, consequentemente aumentar sua vida útil. Ele faz uma revisão detalhada sobre diversos métodos matemáticos utilizados para estimativa do SOC, separando os métodos em: medição direta, contagem de Coulomb, sistemas adaptativos e métodos híbridos.

Os modelos de medição direta apresentados são o de tensão de circuito aberto (*Open Circuit Voltage* - OCV), tensão do terminal (*Terminal Voltage Method*), impedância (*Impedance Method*) e impedância espectroscópica (*Impedance Spectroscopy Method*). São apresentados dois modelos de contagem de Coulomb, o padrão e outro modificado (*Modified Coulomb Counting Method*). Os modelos adaptativos são a rede neural de retro-propagação (*Back Propagation Neural Network*), rede neural de função de base radial (*Radial Basis Function Neural Network*), lógica Fuzzy (*Fuzzy Logic Method*), máquina de vetores (*Support Vector Machine*), rede neural Fuzzy (*Fuzzy Neural Network*) e o Filtro de Kalman. Os modelos híbridos apresentados são o de contagem de Coulomb com medição da forma eletromotriz (*Coulomb Counting and Electromotive Force Combination*), contagem de Coulomb com FK (*Coulomb Counting and Kalman Filter*) e um sistema por unidade com um FK extendido (*Per-Unit System and Extended Kalman Filter Combination*). Após a apresentação dos métodos, é dito que o futuro desta tecnologia deve estar nos modelos híbridos, pesquisas em como adicionar características reais da aplicação ao modelo de predição, considerar os efeitos de envelhecimento e alteração de parâmetros internos da bateria com modelos adaptativos, além de um contínuo desenvolvimento nos algoritmos de redes neurais baseado em dados para se obter uma maior precisão.

[Stefanopoulou e Kim 2015](#) descrevem os conceitos teóricos como o SOC, estado de saúde (*State of Health* – SOH) e estado de energia (*State of Power*), todos relacionados ao gerenciamento de carga de uma bateria e que são controlados durante sua utilização pelo sistema de gerenciamento (*Battery Management System* – BMS). O gerenciamento térmico também foi abordado, já que se evidenciou o desempenho ruim das baterias de Íons de Lítio em

temperaturas baixas.

[How et al. 2019](#) apresentam um trabalho de revisão de vários trabalhos com diferentes métodos de estimativa do SOC, destacando os métodos baseados em modelagem e baseados em dados. Os métodos baseados em modelagem tentam modelar o comportamento físico e químico de uma célula de bateria através de equações diferenciais matemáticas complexas para poder estimar o SOC com maior precisão. Já os modelos baseados em dados, necessitam de uma grande base de dados para poder treinar seus algoritmos e torná-los o mais preciso possível.

É descrito primeiramente o método de consulta da tabela OCV-SOC, que fornece uma relação direta entre esses dois parâmetros. A seguir é mostrado o tradicional método de contagem de Coulomb (*Coulomb Counting*), antes de se aprofundar nos modelos de modelagem e dados. Na descrição dos métodos de modelagem são apresentadas as diversas equações diferenciais que regem o comportamento da bateria durante sua utilização e o objetivo é desenvolver um algoritmo que solucione essas equações. Por fim, os modelos baseados em dados são apresentados: redes neurais (*Neural Network*), aprendizagem profunda (*Deep Learning*), máquina de vetores (*Support Vector Machine*), lógica Fuzzy (*Fuzzy Logic Method*) e modelos híbridos.

O principal desafio apresentado na estimativa do SOC é melhorar a precisão, eficácia e robustez dos algoritmos com baixa complexidade computacional para que o mesmo possa ser implementado em um hardware de BMS de baixo custo. Os erros na estimativa do SOC são gerados muitas vezes pelos próprios sensores de corrente e tensão utilizados, modelos matemáticos imprecisos da bateria, SOC inicial, seleção dos parâmetros internos, dentre outros. Um dos grandes desafios que precisam ser solucionados é a inconsistência dos valores de SOC em cada célula que compõe o grupo de baterias, já que dentro de um grupo de baterias que formam os pacotes de alta tensão existem diversas células conectadas em série e paralelo, o que faz com que a estimativa do SOC para o grupo de células se torne mais difícil. Altas temperaturas também prejudicam muito a estimativa, já que provocam efeitos que alteram o comportamento das células como a fuga térmica que pode ser originada tanto por motivos mecânicos, como colisões ou acidentes, motivos elétricos, como sobrecarga e também por altas temperaturas.

Conforme ocorre a utilização destas células, existe uma redução da sua capacidade de carga total e este também é um dos fatores que prejudicam a estimativa já que alteram, por exemplo, os valores iniciais e máximos a serem considerados nos cálculos do algoritmo. Outro problema muito importante está no material composto da bateria de Íons de Lítio que, embora

tenha ótimas características, podem variar seu desempenho de forma significante dependendo de seus eletrodos positivo e negativo. Monitorar e garantir que a bateria esteja funcionando corretamente e de forma segura, sem que efeitos de sobretensão, sobrecorrente, super aquecimentos ou baixas temperaturas aconteçam, também é um desafio e está diretamente relacionado à precisão do cálculo do SOC, já que estes efeitos alteram as características das células de bateria.

Existem desafios relacionados também a bancada de testes que é utilizada, relacionado aos ruídos, interferência magnética dos sinais aquisitados e precisão do equipamento, já que a obtenção desses dados está diretamente relacionada com a qualidade dos dados que poderão ser utilizados no desenvolvimento de um algoritmo. O último desafio mencionado é justamente conseguir implementar um algoritmo de estimativa do SOC em um BMS de baixo custo, que não necessite de muito armazenamento de memória e que seja rápido computacionalmente para que possa ser utilizado em uma aplicação embarcada.

A conclusão desta revisão é que tanto os algoritmos baseados em modelagem quanto os baseados em dados produziram resultados e avanços significativos na estimativa do SOC, sendo que, para uma aplicação onde o modelo do sistema seja conhecido previamente, os algoritmos baseados nas equações diferenciais são mais eficientes, mas para aplicações onde o sistema não é totalmente conhecido, o modelo baseado em dados pode ter desempenho superior.

Métodos como o de contagem de Coulomb são de malha aberta e não são considerados eficientes pois acumulam muito erro ao longo de sua aplicação, assim como o modelo de consulta da tabela OCV–SOC. Os modelos eletroquímicos têm um custo computacional alto para solucionar as equações diferenciais parciais (*Partial Differential Equation* – PDE) e este fator é um limitante para sua aplicação embarcada. Os modelos ECM precisam de um tempo substancial para estimar os parâmetros e obter um equilíbrio entre acurácia e complexidade computacional. O FK contém complexas operações matriciais que dificultam sua aplicação em microcontroladores de baixo custo, além de que seu desempenho degrada conforme as incertezas da configuração do modelo da bateria, nível de ruído, parâmetros físicos e condições iniciais. As redes neurais artificiais são eficientes para estimar o SOC sob diversas características de aplicação, mas seu desempenho está limitado a duração, qualidade dos dados e definição de hiperparâmetros utilizados em seu treinamento. A lógica Fuzzy precisa de parâmetros muito específicos e difíceis de se obter devido as variações dos parâmetros da bateria sob diferentes perfis de carga e descarga. O sistema de inferência *neuro-fuzzy* adaptativo (*Adaptative Neural Fuzzy*

Inference System – ANFIS) necessita de uma grande quantidade de espaço de memória para armazenamento dos dados, inviabilizando sua aplicação embarcada, enquanto nos modelos híbridos o algoritmo genético (*Genetic Algorithm*) tem uma resposta lenta devido a complexidade dos cálculos realizados e o algoritmo de otimização de partículas (*Particle Swarm Optimization*) tem baixa velocidade de convergência de seus resultados durante o processo iterativo.

Devido a estas preocupações as orientações dadas para o desenvolvimento futuro destes algoritmos são fazer uma modelagem precisa do modelo eletroquímico da bateria em relação a variação dinâmica de seus parâmetros, pesquisa e desenvolvimento de algoritmos para serem embarcados nos hardwares de BMS, controle para equilibrar o SOC das células dentro de um agrupamento de alta tensão, ser criterioso na escolha dos parâmetros do modelo da bateria e os hiper parâmetros de um modelo baseado em dados, tal como desenvolver outras técnicas de otimização para estes modelos e considerar a importância da aplicação real ao problema, já que a dinâmica real da aplicação não pode ser simulada no laboratório e, desta forma, a estimativa do valor do SOC pode ter uma série de incertezas. Sendo assim os autores deste trabalho acreditam que essas sugestões fariam uma grande contribuição ao contínuo desenvolvimento destes algoritmos no futuro.

Os modelos mais simples, como de Contagem de Coulomb (*Coulomb Counting*), não apresentam robustez quanto aos ruídos do sistema ou falhas na medição do sensor e normalmente vem sendo aplicados em conjunto com outros métodos. [Singh et al. 2020](#) modificaram um circuito equivalente fornecido no *Matlab* adicionando 3 pares resistor-capacitor (RC) em série com a resistência interna e utiliza a função “*Isqnonlin*” para otimizar os valores destes parâmetros. Para estimar o SOC foi feito uma combinação do método de contagem de Coulomb e tensão de circuito aberto, o resultado ainda é corrigido utilizando algoritmos baseados em ANFIS considerando o efeito da temperatura na variação do SOC.

Os resultados foram comparados em 3 situações diferentes, primeiro sem a adição dos pares RC, segundo com a adição dos pares RC e, por fim, com a correção do erro através do algoritmo ANFIS. O circuito com 3-RC envolve mais perdas devido a impedância, enquanto no outro modelo apenas as perdas devido a resistência interna são consideradas, mas os testes mostraram que o circuito com 3-RC possui resultados mais próximos dos dados reais simulados.

Após a otimização dos parâmetros com o algoritmo ANFIS, os resultados foram muito próximos dos dados reais com baixo desvio, verificando a utilidade do projeto proposto para sistemas em tempo real. O sistema completo foi validado em tempo real usando configu-

ração de laboratório *hardware in-the-loop* e neste trabalho todo o sistema de bateria foi testado com 420V ao invés de uma única célula, obtendo resultados satisfatórios.

Para extrair os parâmetros que representam as reações eletroquímicas da bateria, o método mais tradicional entre as aplicações embarcadas é o ECM. Os modelos são continuamente desenvolvidos para caracterizar com maior precisão os parâmetros da bateria que irão servir como dados de entrada para a estimativa do SOC. Eles apresentam boa precisão nos cálculos e têm seu custo computacional compatível com aplicações reais embarcadas. No entanto, sua utilização é em grande maioria em conjunto com algoritmos de estimativa baseados em dados, como Redes Neurais Artificiais e Filtros de Kalman, que usam esses parâmetros estimados para calcular o SOC.

[Wang et al. 2016](#) apresentam um estimador adaptativo baseado em probabilidade para obter com precisão valores do SOC, através de um modelo de circuito equivalente resistor capacitor (RC) em combinação com um modelo eletroquímico e do estado de energia (*State of Energy* – SOE) via uma rede neural de janela deslizante (*Sliding Window Neural Network*) para obter a relação entre a tensão do terminal e as entradas do modelo. Uma bancada de testes foi estruturada e diferentes perfis dinâmicos de corrente foram testados para obter os resultados deste modelo.

O teste com o perfil de caracterização de potência de pulso híbrido (*Hybrid Pulse Power Characterisct* - HPPC) mostrou que o modelo baseado em dados e o modelo de rede neural obtiveram erros de tensão de ± 10 mV e ± 20 mV, indicando que uma previsão precisa pode ser fornecida por estes modelos. O teste de estresse dinâmico (*Dynamic Stress Test* – DST) mostrou que o erro do modelo proposto foi de ± 8 mV. O erro máximo absoluto estimado (*Maximum Absolute Estimated Error* – MAEE) e a raiz do erro quadrático médio (*Root Mean Square Error* – RMSE) para a estimativa do SOC com base no modelo proposto são de 0, 97% e 0, 53%, respectivamente, em contraste com 3, 19% e 2, 68% apresentados pelo FK extendido (*Extended Kalman Filter* – EKF). Para o cálculo do SOE o modelo proposto também foi superior com valores de MAEE e RMSE abaixo de 2%, enquanto o EKF apresentou resultados de 3, 96% e 2, 75%, respectivamente.

Finalmente, um perfil UDDS foi executado e seus resultados mostraram que para a estimativa do SOC o modelo proposto apresentou o MAEE e o RMSE de 1, 31% e 0, 88%, respectivamente, enquanto os resultados com base no EKF foram de 3, 62% e 3, 05%, respectivamente. Para estimativa do SOE a partir do perfil UDDS o modelo proposto apresentou MAEE

e RMSE inferiores a 2,5% e 2%, respectivamente, enquanto o modelo com base no EKF teve resultados de 4,11% e 3,38%.

[Eddahech et al. 2012](#) demonstram um modelo para uma célula com base em medições de Espectroscopia de Impedância Eletroquímica baseado em uma abordagem de ECM e em seguida uma RNA Recorrente (*Recurrent Neural Network*) para estimar o SOH da bateria. Os parâmetros são obtidos através de um modelo de 1^a ordem seguido de duas RNAs para estimar o SOC. A função de ativação da rede neural é uma sigmóide com 7 neurônios na camada de entrada e 6 neurônios ocultos, baseados no algoritmo de retro-propagação e com erro quadrático médio (*Mean Square Root*) de 0,462 e 0,296 para valores normalizados de capacidade e resistência, respectivamente. Esses resultados mostram uma contribuição para o desenvolvimento de sistemas automatizados em tempo real para monitoramento dos parâmetros de saúde da bateria.

[Yang et al. 2017](#) utilizam um ECM de primeira ordem para estimar os parâmetros de entrada de uma RNA (*Back Propagation Neural Network - BPNN*), os parâmetros podem ser usados para treinar a BPNN de três camadas e a mesma é utilizada para estimar o SOH. Os testes com perfil de corrente estático e dinâmico verificaram que a precisão do modelo proposto é adequada para estimar o SOH com baixo custo de computação. Os resultados mostraram que a resistência ôhmica R_0 aumenta quando reduzimos o SOH e que durante o intervalo de 20% a 90% do SOC, R_0 aumenta conforme o SOC diminui. Os parâmetros R_p e C_p variam de forma não linear e não foi possível concluir com clareza uma relação direta. Para estimar o SOH foi utilizado 5 baterias para o treinamento da RNA e outras 5 de validação da estimativa, que obteve erro máximo de 7,2% e que poderia ser menor caso fossem utilizados mais dados de treinamento. Este modelo proposto apresentou vantagens como o baixo custo de computação, baixo custo de memória e fácil entendimento. A precisão poderia ser melhor, mas depende do algoritmo utilizado, quantidade de dados de treinamento e precisão do modelo ECM escolhido.

[Chi et al. 2013](#) utilizam os parâmetros extraídos de um ECM e algoritmos de Filtro de Partículas (FP) e um FK (*Unscented Kalman Filter - UKF*) para prever o SOC, tensão final de descarga (*End of Discharge Voltage - EODV*) e o tempo de vida restante (*Remaining Usefull Life - RUL*) da bateria durante o voo de um veículo elétrico não tripulado. O resultado mostrou uma melhoria considerável nas implementações baseadas em filtros de partículas e prognósticos do EODV, tanto em relação a precisão do modelo quanto a estabilidade durante o voo.

[Xing et al. 2014](#) desenvolveram um algoritmo de UKF que otimiza o erro do sistema

em conjunto com um ECM de resistência interna simplificado para estimar o SOC de acordo com uma tabela OCV-SOC e um parâmetro que considera a influência da temperatura ambiente, fator que altera muito a precisão da estimativa do SOC, o diagrama de blocos do trabalho pode ser visto em (Figura 1.2).

Foram feitos dois testes dinâmicos, o DST e o de direção urbana federal (*Federal Urban Driving Schedule – FUDS*), para validar o desempenho do modelo proposto. Os resultados dentro da faixa de 25% a 85% do SOC indicaram um erro de raiz quadrada média menor que os métodos que não corrigem o modelo levando em consideração a temperatura ambiente, portanto o modelo proposto poderia ser efetivamente aplicado em sistemas de gerenciamento de baterias para veículos elétricos. Além disso, o trabalho também observou que o erro do SOC estimado no modelo sem correção para temperaturas em 10°C é maior que a 40°C, causado pela imprecisão da tabela OCV-SOC em baixa temperatura.

Por fim, os resultados foram satisfatórios com RMSE abaixo de 5% nos testes com temperaturas de 10°C e 40°C, ainda que para a temperatura de 0°C tenha sido observado RMSE de até 16% para SOC inicial de 75% para o modelo corrigido e 25% para o modelo sem correção de temperatura.

[Guo et al. 2019](#) realizaram uma série de testes em um ECM (Figura 1.3) para fornecer suporte de dados para a identificação dos parâmetros da bateria e em seguida aplica um FK estendido para estimar o SOC e utiliza uma técnica de Hardware-in-the-Loop (HIL) para validar o sistema. A simulação HIL e o teste em bancada mostraram um erro de estimativa do SOC do BMS menor que 5% no caso de instabilidade na tensão de circuito aberto da bateria, com uma boa robustez e confiabilidade.

[Fang et al. 2019](#) propõem um ECM com um fator de esquecimento recursivo dos mínimos quadrados (*Forgetting Factor Recursive Least Squares*) para realizar a identificação dos parâmetros do modelo e desenvolve um estimador de conjunto utilizando um FK duplo (*Double Extended Kalman Filter*) para estimar o SOC e o SOH. O resultado dos experimentos realizados mostrou que o erro máximo da estimativa de SOC é de 1,08% e do SOH é de 1,52%, além de que a curva OCV-SOC tem a maior influência no erro de estimativa em comparação aos valores da capacidade da bateria e seus parâmetros. Como um sistema de bateria consiste em uma dinâmica rápida e outra lenta, o método clássico dos mínimos quadrados (*Least Swuare – LS*), que estima todos os parâmetros do modelo, sofre com problemas e baixa precisão.

[Zhang et al. 2018](#) sugerem um novo método de LS (*Decoupled Weighted Recursive*

Least Squares) que estima separadamente os parâmetros de dinâmica rápida e lenta da bateria. Uma simulação foi feita para comparar os resultados do modelo proposto contra a técnica LS e os resultados mostraram que o método proposto pode melhorar não apenas a precisão da modelagem, mas também o desempenho de estimativa do SOC, já que apresentou RMSE de 0,86% contra 2,98% do tradicional LS.

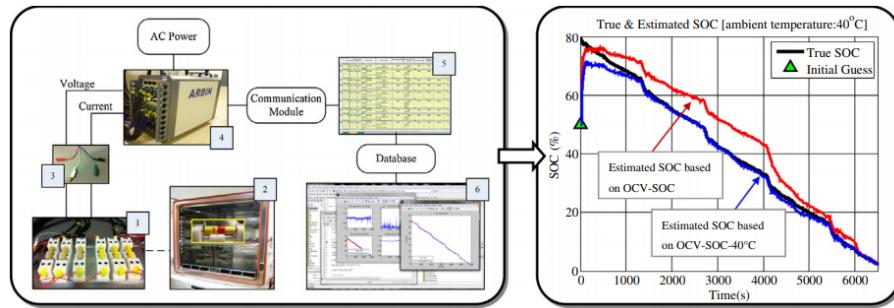


Figura 1.2 – Figura extraída do artigo [Xing et al. 2014](#)

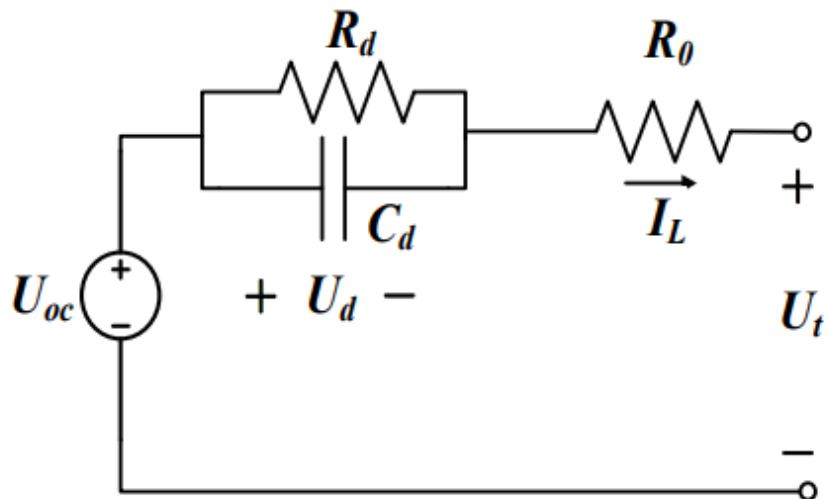


Figura 1.3 – Figura extraída do artigo [Guo et al. 2019](#)

Os métodos orientados a dados vêm sendo amplamente desenvolvidos nos trabalhos de pesquisa, as RNA e os algoritmos de filtragem como o FK e o FP são os mais populares devido a sua precisão, capacidade de adaptação e treinamento aos diversos casos de aplicação do problema ao estimar os parâmetros da bateria. [Nunes et al. 2018](#) utilizaram uma RNA para estimar o SOC da bateria em duas partes, primeiro estimando a tensão a partir dos dados de corrente e temperatura e depois estimando o SOC a partir dos dados de tensão, corrente, temperatura e realimentação do valor do SOC. A RNA foi desenvolvida com capacidade de aprendizagem e adaptação aos ciclos de carga, descarga e descanso de uma bateria de Íons de Lítio, se mostrando muito precisa nos testes realizados.

[Zahid e Li 2016](#) compararam algoritmos de filtragem como o EKF, UKF e o FP para estimar o SOC de baterias de LiFePO₄ para um veículo elétrico. Os parâmetros da bateria são identificados a partir de um modelo equivalente de Thevenin. Os resultados mostraram que quanto maior a ordem da função polinomial, melhores resultados são obtidos na estimativa. Durante os testes percebeu-se que todos os métodos utilizados, tiveram erros grandes quando o SOC estava entre 45% a 65% e que, quando um SOC incorreto era dado inicialmente, o FP era mais afetado em relação aos demais, demorando mais para recuperar o erro de inicialização. O UKF provou-se melhor que o EKF, embora também tenha sofrido com a recuperação do erro de inicialização e o FP superou o EKF quando o modelo da bateria foi afetado por um ruído gaussiano ou quando um modelo de ordem superior foi utilizado, neste último caso superando até mesmo o UKF. Estes resultados mostraram que ambos os métodos podem ser aplicados e cada um tem características melhores que o outro dependendo do problema de aplicação.

[Zhao et al. 2019](#) basearam seu trabalho em modelos de aprendizagem profunda (*Deep Learning*) e revisa sistemas como autoencoders (*Autoencoders*), máquina Boltzmann restrita (*Restricted Boltzmann Machine*), uma classe de RNA (*Deep Belief Network - DBN*), outra classe da máquina Boltzmann (*Deep Boltzmann Machine*), RNA Convolucional (*Convolutional Neural Network*), RNA Recorrente (*Recurrent Neural Network*) e novas tendências de monitoramento. O trabalho conclui que o aprendizado profundo aplicado em sistemas de monitoramento de saúde da máquina (*Machine Health Monitoring Systems*) depende fortemente da quantidade e qualidade dos dados utilizados e a extração de parâmetros dos modelos monitorados pode reduzir a complexidade das camadas ocultas.

[Hannan et al. 2018](#) tiveram como objetivo melhorar a capacidade de uma BPNN utilizando um algoritmo de busca (*Backtracking Search Algorithm - BSA*) a fim de melhorar a precisão e robustez do modelo da RNA, encontrando o melhor valor de neurônios da camada oculta, taxa de aprendizado, dentre outros (Figura 1.4). Para testar o modelo em diferentes temperaturas foi utilizado um perfil DST, um FUDS e os resultados obtidos mostraram que o modelo BSA baseado em BPNN supera os outros modelos de rede na estimativa de SOC com alta precisão em diferentes perfis e temperaturas. Observou-se também, que conforme a temperatura aumenta, o erro da estimativa do SOC diminui e a faixa de erro a 45°C do modelo BPNN está entre -3,5% e 4,3% para o ciclo FUDS e -2,4% e 3,3% para o ciclo DST. Já para o modelo BPNN-BSA, o erro na estimativa é de -2,4% e 3,5% e para o ciclo FUDS está entre -2,1% e 3,2%, já para valores de temperatura mais baixos, como 0 °C o erro chega até quase

10%.

Zhang *et al.* 2019 treinaram um modelo de mínimos quadrados e máquina de vetores (*Least-Squares Support Vector Machine*) com um pequeno conjunto de amostras para determinar as características dinâmicas da bateria e utilizou um UKF baseado no modelo para estimar o SOC. Os resultados da simulação com os dados de teste HPPC e FUDS confirmam que a abordagem proposta pode produzir um modelo mais simplificado e ainda mais preciso. O erro absoluto da estimativa do SOC após o UKF nos testes realizados varia de -0,02% a 0,06% quando o SOC é entre 10% e 90% para o teste HPPC, da mesma forma o erro varia entre -0,01% a 0,02% para o teste FUDS.

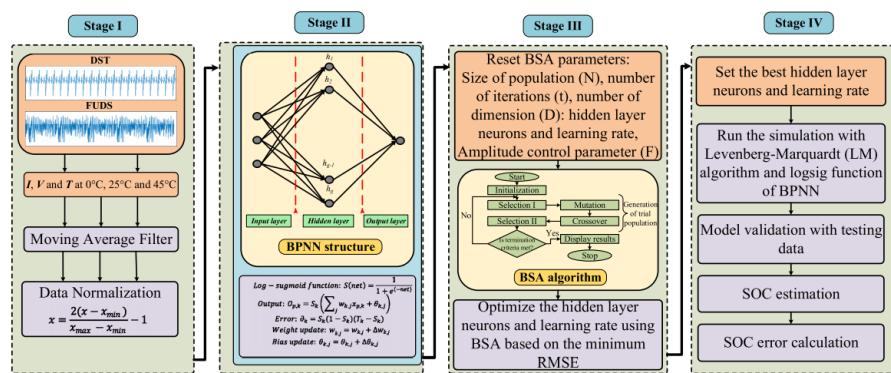


Figura 1.4 – Figura extraída do artigo Hannan *et al.* 2018

Os EM são os métodos mais precisos para determinar os parâmetros da bateria pois em sua maioria se baseiam em Equações Diferenciais Parciais (EDPs) para descrever o comportamento dinâmico da bateria. Apesar de serem muito precisos os cálculos de EDPs podem ter alto custo computacional, o que acaba limitando sua aplicação em sistemas embarcados. Li *et al.* 2015 apresentaram um modelo tridimensional que abrange a conservação de carga, massa, energia e a reação eletroquímica de uma bateria de Fosfato de Ferro e Lítio, investigando as propriedades eletroquímicas internas. Os resultados indicaram que os gradientes máximos das propriedades estão na região de transição entre as guias e as placas de eletrodo. Para a bateria de LiFePO₄/Grafite o ânodo desempenha um papel mais importante que o cátodo no potencial e é provável que seja crucial na diminuição acentuada da tensão de saída no processo de descarga da célula, além de que a quantidade de material do ânodo pode fornecer uma maior capacidade para a bateria. Este modelo forneceu um eficiente método para observar as informações detalhadas sobre a distribuição espacial e temporal dos comportamentos eletroquímicos internos em uma bateria de Íons de Lítio, como distribuição de potencial elétrico transitório, distribuição de sobre potencial, distribuição do SOC, local de distribuição de densidade de corrente e distribui-

ção de concentração de íons de lítio, que são difíceis de se obter por experimentos de métodos tradicionais.

[Hosseinzadeh et al. 2017](#) apresentaram um EM térmico unidimensional de um par de eletrodos de uma bateria de Íons de Lítio desenvolvido no software *Comsol Multiphysics* e validado para uma célula de Fosfato de Lítio para realizar análises estatísticas dos parâmetros mais influentes que determinam o desempenho da célula. Os parâmetros analisados foram: raio de partícula (rp), espessura do eletrodo (L_{pos}), fração de volume do material ativo ($\epsilon_{s,pos}$), taxa C, energia específica e potência específica. Sendo assim, observou-se que a energia ótima pode ser alcançada quando $rp \leq 40 \text{ nm}$, $75 \mu\text{m} \leq L_{pos} \leq 100 \mu\text{m}$, $0,4 \leq \epsilon_{s,pos} \leq 0,6$ e enquanto a taxa C estiver abaixo de 4C. Por outro lado, a potência ótima é obtida para um eletrodo fino quando $L_{pos} \leq 30 \mu\text{m}$, alta porosidade e taxa C. Como não podemos alcançar o ideal de energia e potência ao mesmo tempo, a bateria deve ser projetada de modo que a relação potência/energia seja satisfatória para a aplicação específica.

[Chen et al. 2019](#) mostraram um EM simplificado de eletrodo que adota uma aproximação polinomial e um método de três variáveis, propondo um novo método de identificação de parâmetros considerando temperatura e corrente para reduzir o desvio causado por diferentes condições. Os parâmetros do modelo são identificados pelo algoritmo genético offline em diferentes temperaturas e correntes para criar tabelas de pesquisa para estimativas online. As células escolhidas para validação do modelo simplificado e método de estimativa proposto são do tipo 18650 3,5 Ah NCM. Os resultados indicam que o esquema proposto é preciso, simples e flexível para mudanças de corrente e temperatura para diferentes condições de operação. O modelo simplificado combinado com o método de identificação de parâmetros proposto atualiza os parâmetros com um erro de tensão de aproximadamente 0,056V, erro de tensão relativo entre 0 a 0,7% e uma média do erro de tensão relativo de 0,2%.

[He et al. 2018](#) propuseram um modelo eletroquímico para estimativa de SOC de bateria de Íons de Lítio envolvendo as propriedades internas físicas e químicas da bateria como, por exemplo, as concentrações de lítio (Figura 1.5). Para resolver computacionalmente as complexas PDEs de difusão em fase sólida no modelo, um método eficiente com base na projeção com funções de base otimizadas é apresentado. Então, um algoritmo de filtragem de janela móvel (*Moving Window Filtering*) é desenvolvido para melhorar a taxa de convergência dos filtros de estado. Os resultados mostraram que o modelo eletroquímico desenvolvido gera 20 vezes menos equações em comparação com métodos baseados em diferenças finitas, sem perder a

precisão. Além disso, a proposta baseada em projeções do método de solução é três vezes mais eficiente do que os métodos convencionais de filtragem de estado, como o FK.

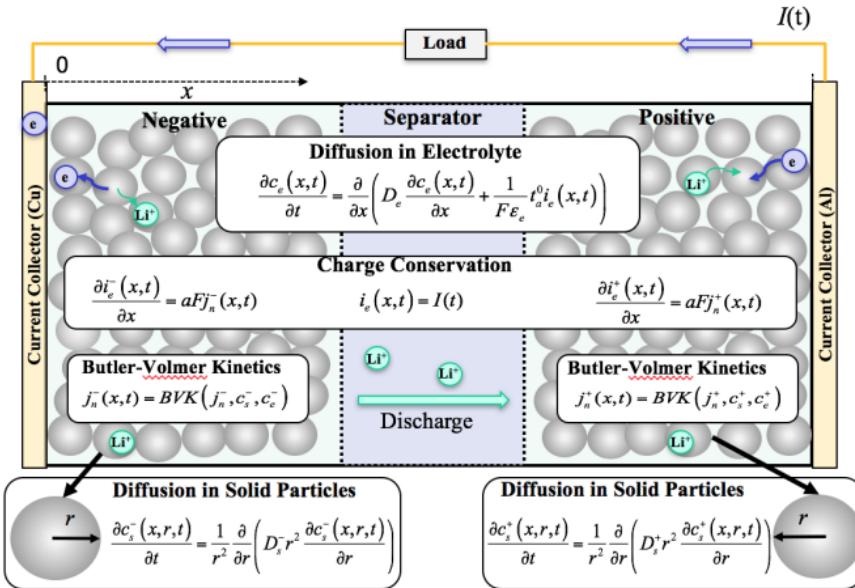


Figura 1.5 – Figura extraída do artigo He et al. 2018

Os métodos híbridos, contendo 2 ou mais sistemas integrados para melhorar o desempenho da estimativa e controle dos parâmetros da bateria, vem sendo cada vez mais presentes nas pesquisas e aplicações para muitos tipos de problema, como estimar os parâmetros de saúde de uma bateria. Conseguir absorver as qualidades de cada um tem sido uma boa estratégia de aplicação e gerando bons resultados, sendo apontada como maior potencial de desempenho em projetos futuros. Combinar a precisão de EM baseados em equações diferenciais com a otimização dos cálculos computacionais dos métodos orientados a dados, por exemplo, pode ser um caminho para solucionar muitos problemas embarcados em tempo real, que muitas vezes requerem maior precisão e adaptação a diferentes situações que as oferecidas por modelos orientados somente por dados.

Tulsky et al. 2016 demonstraram um algoritmo original para estimativa do SOC usando um modelo pseudo bi-dimensional (*Pseudo-Two-Dimensional* – P2D). As equações diferenciais parciais são discretizadas usando algoritmos em um modelo de espaço de estado não linear. Este modelo discreto de alta dimensão, consistindo de dezenas a centenas de estados, contém equações algébricas não lineares implícitas. A incerteza no modelo é caracterizada por ruído gaussiano aditivo. Explorando a estrutura especial do modelo pseudo-bidimensional, um novo algoritmo de FP que varre no tempo e nas coordenadas espaciais de forma independente,

foi desenvolvido. O SOC e outras propriedades da bateria que dependem de variáveis de estado não medidas, como as concentrações e potenciais são estimados através do FP desenvolvido. O algoritmo usa uma nova técnica para reduzir a complexidade computacional e uma simulação mostra que o algoritmo proposto fornece estimativa precisa do SOC na presença de estado significativo e ruído de medição. O modelo P2D é um dos modelos mais sofisticados, no entanto, não leva em conta a saúde da bateria, pois ela muda com a carga e ciclos de descarga. O trabalho conclui que o algoritmo proposto pode ser facilmente adaptado para integrar as equações do estado de saúde no modelo P2D.

[Farfán et al. 2020](#) abordaram o problema através de uma aplicação diferente que o da obtenção dos parâmetros de saúde da bateria, mas conceitualmente a ideia segue o mesmo caminho e é muito importante para o desenvolvimento dos modelos híbridos. Foi avaliado a precisão de dois modelos físicos, dois modelos baseados em RNA e proposto um sistema híbrido usando as séries temporais geradas pelos modelos individuais como entrada de uma nova RNA. Os resultado indicaram que a técnica híbrida, utilizando equações e dados, foi capaz de melhorar o desempenho individual dos modelos físicos e baseados apenas em RNA.

[Karpatne et al. 2017](#) apresentaram uma nova estrutura para combinar o conhecimento científico de modelos baseados em física com redes neurais (*Physics-guided Neural Network*), utilizando a saída do modelo baseado em física junto com recursos observacionais para gerar previsões usando uma arquitetura de RNA e aplicando o método para um problema de modelagem da temperatura de um lago. Além disso, este artigo apresenta uma nova estrutura para o uso de funções de perda baseadas na física para o aprendizado de redes neurais, garantindo que as previsões do modelo não apenas mostrem erros menores no conjunto de treinamento, mas também sejam cientificamente consistentes com a física conhecida do problema em questão. Através do conhecimento científico para guiar a construção e aprendizagem de redes neurais, a estrutura proposta garantiu melhor generalização e consistência científica dos resultados apresentados. Este resultado nos mostra que estes algoritmos podem possuir tanto as vantagens dos métodos baseados nas características físicas quanto nos modelos baseados em dados, mantendo a eficácia do sistema mesmo para aplicações onde os dados reais são muito divergentes dos utilizados durante o treinamento.

[Kharazmi et al. 2019](#) desenvolveram uma versão de uma RNA baseada na física (*Physics Informed Neural Networks - PINNs*) de Petrov-Galerkin com base na aproximação linear de uma RNA profunda (*Deep Neural Network*) selecionando o espaço para as redes neu-

rais e polinômio de Legendre. O residual variacional das PDEs é formulado usando a aproximação de DNNs, incorporando a forma variacional do problema na função de perda da rede neural e construindo uma forma variacional informada pela física da rede neural (*Variational Physics-Informed Neural Network - VPINN*) (Figura 1.6). Desta forma, a ordem dos operadores diferenciais representados pelas redes neurais diminuiu, reduzindo efetivamente o custo de treinamento em VPINNs e aumentando sua precisão quando comparada a PINNs. Foi demonstrado vários exemplos onde foi observado claras vantagens das VPINNs sobre as PINNs em questão de precisão da estimativa e velocidade de desempenho.

[Raissi et al. 2017](#) introduziram o conceito de redes neurais informadas pela Física, que são treinadas para resolver tarefas de aprendizado supervisionado respeitando uma lei da Física descrita por PDEs não lineares. Foi apresentado dois desenvolvimentos, uma solução orientada a dados e uma descoberta orientada a dados de PDEs. As redes neurais resultantes vão formar uma nova classe de aproximadores de função universal eficientes em dados que codificam naturalmente quaisquer leis Físicas. Essas redes podem ser utilizadas para inferir soluções para PDEs e obter modelos substitutos informados pela Física totalmente diferenciáveis.

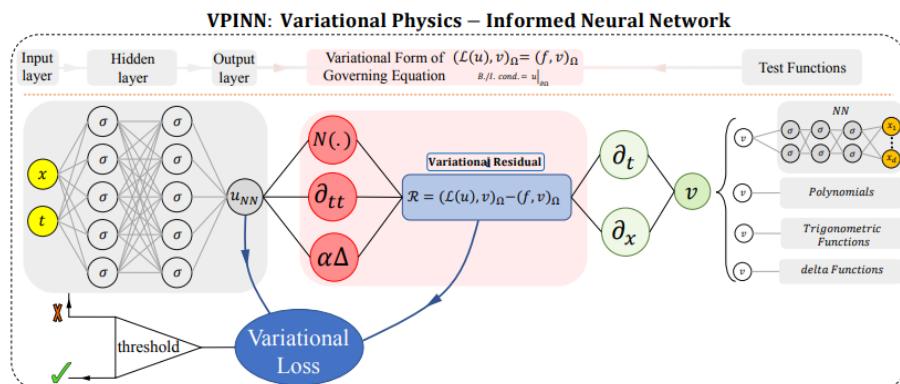


Figura 1.6 – Figura extraída do artigo [Kharazmi et al. 2019](#)

Para ser possível o desenvolvimento de novos modelos no campo de pesquisa é necessário a obtenção de dados de teste em ambientes controlados para utilização desses dados no desenvolvimento do algoritmo. Para isso, é necessário equipamentos especiais e de alto custo para poder testar as células em condições programadas e perfis de carga e descarga desejados. Este fator poderia impossibilitar muitos pesquisadores a evoluírem seus modelos devido ao fato de que este tipo de laboratório não é de acesso fácil para a grande maioria dos desenvolvedores. Sendo assim, algumas instituições importantes disponibilizam banco de dados de simulações de diferentes células de bateria sob diferentes perfis de descarga para fins educativos e de pesquisa, como listado no trabalho [How et al. 2019](#). Este presente trabalho utilizou os dados disponibili-

zados por *Gregory L. Plett da University of Colorado Colorado Springs* (UCCS), mas existem dados semelhantes disponibilizados pela NASA e pelo *Center for Advanced Life Cycle Engineering* (CALCE), dentre outros, que podem ser adquiridos de forma gratuita em suas plataformas na internet para fins de estudo e desenvolvimento.

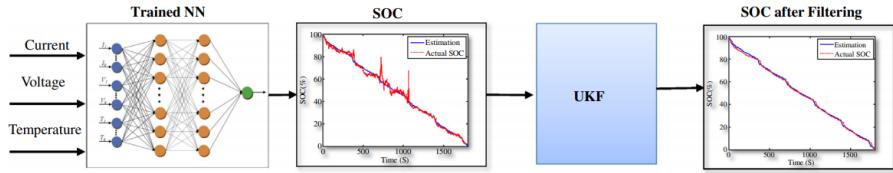


Figura 1.7 – Figura extraída do artigo [He et al. 2014](#)

Todos os trabalhos referenciados auxiliaram na construção deste presente trabalho para direcionar a metodologia e quais as tendências nas quais acredita-se serem positivas para contribuir no desenvolvimento de tecnologia.

1.3 Desenvolvimentos Propostos

Há um grande esforço em otimizar algoritmos e modelos de bateria, reduzir a ordem de equações diferenciais para aplicá-las em sistemas embarcados e melhorar a precisão do sistema, desenvolver modelos híbridos para melhorar o desempenho do algoritmo, dentre outros. Algoritmos de estimativa para cálculo do SOC utilizam modelos eletroquímicos ou baseados em dados bastante desenvolvidos e comuns de serem vistos em aplicações embarcadas. Porém, para que se possa chegar a um nível ainda maior de precisão, é necessário considerar fatores que não estão vinculados as características da bateria, mas sim ao agente principal que vai determinar o consumo de energia: o piloto.

Neste contexto, os KPIs da pilotagem são parâmetros que agregam dados relevantes para maior precisão na estimativa do valor de SOC. A agressividade no pedal do acelerador e suavidade no momento de tirar o pé do pedal, estão diretamente relacionados com a quantidade de carga a ser drenada das baterias. No caso do pedal de freio temos a mesma situação. A agressividade do pedal de freio e a suavidade no momento de tirar o pé estão diretamente relacionados com a quantidade de corrente a ser utilizada para recarregar as baterias no momento da regeneração da energia.

Este trabalho elaborou um algoritmo híbrido para estimativa do SOC em veículos de competição, a partir de um modelo proposto e desenvolvido por Gregory Plett, University of Colorado Colorado Springs - UCCS, disponibilizado e protegido por direitos autorais, podendo

ser utilizado apenas para fins educativos e informativos, tal como este trabalho, que utiliza um modelo de ECM e um KF para estimar o SOC da bateria. Para acrescentar o desenvolvimento baseado nos dados de pilotagem e criar um modelo híbrido foi desenvolvido em conjunto uma RNA com parâmetros externos, os KPIs, que também alteram a curva de consumo de SOC, parametrizando cada piloto e estimando novamente o SOC, com maior precisão e de forma mais personalizada.

1.4 Resumo da Tese

O trabalho se inspirou no estudo desenvolvido por Gregory Plett, onde foi estimado o SOC da bateria aplicando um KF. Para a realização de testes com os algoritmos é necessário um banco de dados de testes de células de baterias. Para isso optou-se pelo banco de uma célula A123 de LiFeP04 de 3,4 V e um perfil de carga e descarga de um veículo urbano, ambos disponibilizados pelo CALCE. A escolha foi embasada por modelo semelhante ao que é utilizado no automobilismo e também pelo perfil dinâmico ser o que mais se assemelha à aplicação deste trabalho.

Após aplicar o modelo de Gregory Plett para a célula A123, foi iniciado o desenvolvimento do modelo híbrido proposto. Conforme os dados do teste do perfil dinâmico de carga e descarga da bateria, foram aplicadas as fórmulas para o cálculo dos KPIs dos pedais de freio e de acelerador, correlacionando estes valores com os sinais de carga e de descarga da bateria. Com os valores extraídos do teste, foi utilizada uma RNA para uma nova estimativa do SOC, com o objetivo de otimizar a precisão do cálculo anterior do KF. Desta forma, um modelo híbrido desenvolvido tanto da parte teórica da bateria quanto da aplicação do problema pode configurar um modelo ideal no desenvolvimento de uma inteligência artificial embarcada para uma melhor precisão dos algoritmos de estimativa do SOC.

2 METODOLOGIA

Neste capítulo é descrito todos os passos para obtenção da estimativa do SOC pelo algoritmo híbrido proposto neste trabalho. Começando com os testes laboratoriais com as células de bateria para obtenção dos parâmetros internos, posteriormente o desenvolvimento do KF que realiza a primeira estimativa do SOC, até a obtenção dos KPIs e desenvolvimento da RNA para realizar a segunda estimativa do SOC. Para obtenção dos resultados foi utilizado um banco de dados com testes de uma bateria A123 de LiFePO₄ de 3,6V com capacidade de 2230 mAh, pois é o mesmo modelo utilizado em diversos veículos elétricos e o mais próximo a nossa aplicação fornecidos para fins educativos e de pesquisa através da CALCE.

Para a obtenção dos parâmetros internos a célula A123 passa por 2 testes laboratoriais, o Teste de Circuito Aberto (*Open Circuit Voltage - OCV*) e o teste com perfil dinâmico de carga e descarga (*Dynamic Urban Dynamometer Driving Schedule - DYN*).

2.1 Teste 1: Tensão de Circuito Aberto

O objetivo deste teste é encontrar a relação do OCV com o SOC já que eles possuem uma relação direta dependente da temperatura e esta relação é necessária para calcular os parâmetros dinâmicos da célula no próximo teste. Para obtenção dos dados de corrente e tensão a conexão com a célula é feita a partir de 4 fios, separando a medição da corrente com a tensão para que não exista influencia de uma queda de tensão no cabo de medição devido a corrente, caso o sistema fosse ligado apenas por 2 fios.

O equipamento de ensaio utilizado em laboratório, assim como os equipamentos da *Arbin Instruments* nos EUA ou da CPqD (Centro de Pesquisa e Desenvolvimento em Telecomunicações) no Brasil, tem como princípio de funcionamento aplicar diversos ciclos de carga/descarga definidos pelo usuário, sendo aplicável a várias células simultaneamente, sob uma temperatura especificada e controlada, gerando como resposta os valores de tensão, corrente e temperatura em um banco de disponibilizado após o teste. Parâmetros de temperatura e umidade do teste são controlados de acordo com as definições de teste, para obtenção dos dados em uma faixa de temperatura, bem como aplicar choques térmicos na célula, se desejado.

O teste foi separado em 10 passos:

Descarregar a célula até a tensão mínima em temperatura de trabalho .

1. Inserir célula no ambiente de teste com a temperatura de trabalho especificada e permanecer ao menos 2 horas para que toda célula atinja temperatura uniforme;

2. Aplicar corrente de descarga constante até que a tensão medida seja igual a mínima estabelecida;

Descarregar a célula até atingir SOC = 0% à 25°C.

3. Mudança de temperatura no ambiente de teste para 25°C e manter célula em repouso ao menos 2 horas para que toda célula atinja temperatura uniforme;

4. Aplicar corrente de descarga até que a tensão medida seja igual a mínima estabelecida;

5. Aplicar um perfil de corrente oscilatório utilizado em desmagnetização para minimizar o efeito da histerese;

Carregar a célula até a tensão máxima em temperatura de trabalho.

6. Mudança de temperatura no ambiente de teste para a temperatura de trabalho especificada e manter célula em repouso ao menos 2 horas para que toda célula atinja temperatura uniforme;

7. Aplicar corrente de carga até que a tensão medida seja igual a máxima estabelecida;

Carregar a célula até atingir SOC = 100% à 25°C

8. Mudança de temperatura no ambiente de teste para 25°C e manter célula em repouso ao menos 2 horas para que toda célula atinja temperatura uniforme;

9. Aplicar corrente de carga até que a tensão medida seja igual a máxima estabelecida;

10. Aplicar um perfil de corrente oscilatório utilizado em desmagnetização para minimizar o efeito da histerese;

2.2 Teste 2: Perfil Dinâmico de Carga e Descarga

O objetivo deste teste foi aplicar um perfil de carga/descarga semelhante a aplicação real para gerar os dados utilizados como entrada do algoritmo, que neste trabalho extraiu os parâmetros do modelo ESC da bateria. O perfil de direção urbana (*Urban Dynamometer Driving Schedule - UDDS*) foi escolhido por ser o perfil disponível mais próximo de uma aplicação em

Motorsports. O ambiente de teste seguiu o mesmo padrão do primeiro, sendo a única diferença entre eles os passos e padrões de corrente que foram aplicados à bateria.

O teste foi separado em 9 passos:

1. Inserir célula no ambiente de teste com a temperatura de trabalho especificada e permanecer ao menos 2 horas para que toda célula atinja temperatura uniforme;
2. Aplicar corrente de descarga a uma taxa de C/1 por 6 minutos para evitar uma sobrecarga nos próximos passos;
3. Executar o perfil UDDS no intervalo de 90% a 10% de SOC;
4. Mudança de temperatura no ambiente de teste para 25°C e manter célula em repouso ao menos 2 horas para que toda célula atinja temperatura uniforme;

Descarregar a célula até atingir SOC = 0% à 25°C

5. Aplicar corrente de descarga a uma taxa de C/30 até que a tensão medida seja igual a mínima estabelecida;
6. Aplicar um perfil de corrente oscilatório utilizado em desmagnetização para minimizar o efeito da histerese;

Carregar a célula até atingir SOC = 100% à 25°C

7. A. Aplicar corrente de carga a uma taxa de C/30 até que a tensão medida seja igual a máxima estabelecida;
8. Manter a tensão constante até que a corrente caia abaixo de C/30;
9. Aplicar um perfil de corrente oscilatório utilizado em desmagnetização para minimizar o efeito da histerese;

2.3 Algoritmo da Tensão de Circuito Aberto

Para obter a relação de OCV e SOC da célula a partir do teste laboratorial foi utilizado um código desenvolvido no software *MatLab* baseado no modelo de *Grogory L. Plett, 2015*.

A fórmula utilizada para calcular o SOC é dada por:

$$z[k] = z[0] - \frac{1}{Q} \sum_{j=0}^{k-1} \eta[j] i[j]. \quad (2.1)$$

Para calcular a eficiência de Coulomb:

$$\eta = \frac{I_{discharged}}{I_{charged}}. \quad (2.2)$$

Onde $I_{discharged}$ é a corrente consumida da bateria e $I_{charged}$ é a corrente que foi utilizada para recarregar a bateria. Para calcular a capacidade total da célula foi utilizado:

$$Q = \sum_{j=0}^{k-1} \eta[j] i[j]. \quad (2.3)$$

A percentagem de carga retirada da bateria durante a descarga (*Depth of Discharge* - DoD) em cada ponto é calculado por:

$$DoD[t] = (TotalAh I_{discharged}) - \eta * (TotalAh I_{charged}). \quad (2.4)$$

Finalmente com a equação 2.1 e 2.4 foi possível definir o cálculo do SOC a cada ponto por:

$$SOC[t] = 1 - \frac{DoD(t)}{Q}. \quad (2.5)$$

A representação do processo de obtenção da relação OCV e SOC pelo fluxograma está ilustrado a seguir (Figura 2.1):

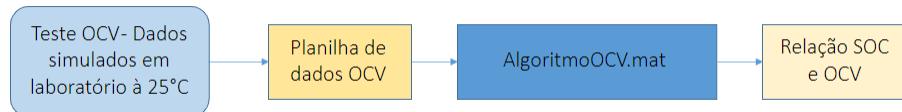


Figura 2.1 – Fluxograma Geral - Incluindo relação OCV-SOC

2.4 Algoritmo do Teste Dinâmico

O Teste 2 forneceu os dados de entrada do perfil UDDS para o código desenvolvido que determinou os parâmetros dinâmicos do modelo ESC da célula.

O processo de obtenção dos parâmetros dinâmicos da célula A123 está representado pelo fluxograma a seguir (Figura 2.2):

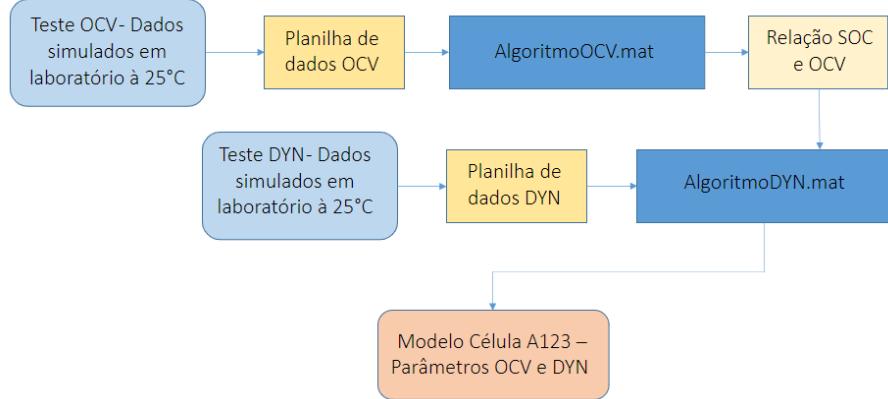


Figura 2.2 – Fluxograma Geral - Incluindo Modelo A123

Os dados de entrada são $i[k]$, $v[k]$ e a tabela OCV vs SOC (obtida no algoritmo de OCV). Novamente são calculados η e Q através das equações 2.2 e 2.3. Em seguida obtemos $z[k]$ a partir da equação 2.1 com $z[0]=0$ e calculamos a tensão ajustada $v_{ajus}[k]$ através da equação:

$$v_{ajus}[k] = v[k] - OCV(z[k], T[k]) \quad (2.6)$$

em que $v[k]$ é a tensão medida e $OCV(z[k], T[k])$ é a relação de OCV e SOC calculada no algoritmo OCV.

Para calcular o parâmetro $R - C$ o algoritmo utiliza uma técnica de identificação de sistema de subespaço e calcula as equações de estado $i_R[k]$, $s[k]$ e $h[k]$ através das equações 2.7, 2.8 e 2.9:

$$i_R[k] = A_{AR} i_R[k - 1] + B_{RC} i_R[k - 1], \quad (2.7)$$

$$s[k] = \text{sgn}(i[k]), |i[k]| > 0, \quad (2.8)$$

$$h[k] = A_H h[k - 1] + (A_H h[k - 1] - 1)\text{sgn}(i[k - 1]). \quad (2.9)$$

O parâmetro de saída, $v_{est}[k]$, é obtido através da equação:

$$v_{est}[k] = OCV(z[k], T[k]) + Mh[k] + Mv_0s[k] - \sum_j R_j i_{Rj}[k] - R_0 i[k]. \quad (2.10)$$

Para calcular o desvio do parâmetro estimado foi utilizado a raiz do erro quadrático médio:

$$rms = \sqrt{\frac{1}{N} \sum_{j=1}^n (v[k] - v_{est}[k])^2}. \quad (2.11)$$

Todos os parâmetros dinâmicos do modelo ESC calculados foram otimizados e atualizados até a obtenção do menor erro quadrático médio da raiz. Por fim, o código retornou uma matriz contendo os dados:

1. QParam - Capacidade Q em Ah
2. etaParam - Eficiência de Coulomb η
3. GParam - Parâmetro γ de Histerese
4. MParam - Parâmetro M de Histerese[V]
5. M0Param - Parâmetro M_0 de Histerese [V]
6. R0Param - Resistência Interna [Ohm]
7. RCParam - Constante de tempo $R - C$ [s]
8. RParam - Resistência do parâmetro $R - C$ [Ohm]

2.5 Filtro de Kalman Ponto Sigma

Após a obtenção dos dados do modelo ESC, é implementado um Filtro de Kalman Ponto Sigma (*Sigma Point Kalman Filter - SPKF*) para estimar o SOC da célula A123 durante a aplicação de um perfil UDDS de corrente de carga/descarga, assim como na simulação com perfil dinâmico de carga/descarga. A resposta deste sistema serviu como dado de entrada para a RNA. Os códigos utilizados foram baseados pelo modelo de Grogory L. Plett, 2015.

O diagrama de blocos do processo incluindo a obtenção do SOC pelo SPKF está representado a seguir (Figura 2.3):

Inicialmente foram carregados os parâmetros do modelo ESC no algoritmo após definida a temperatura de trabalho e armazenamos os valores de tempo, corrente, tensão e SOC

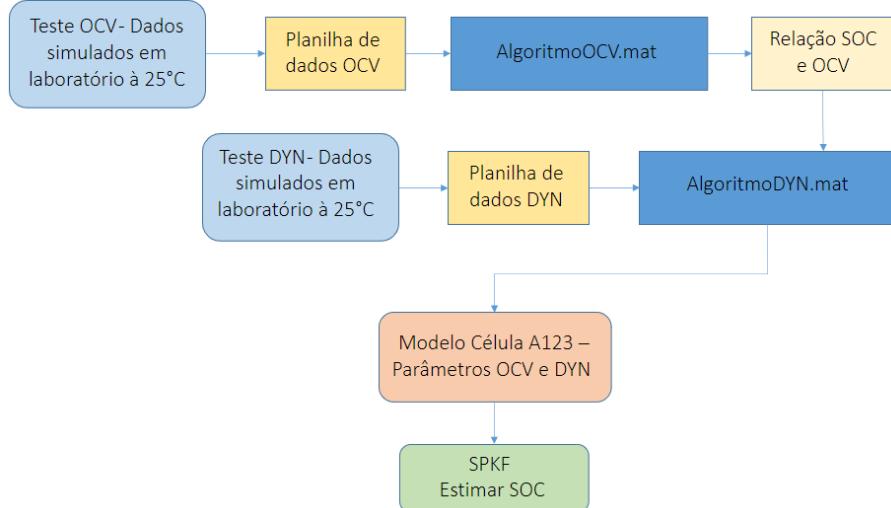


Figura 2.3 – Fluxograma Geral - Incluindo SPKF

obtidos do teste dinâmico em vetores. Também foram definidos os valores iniciais correspondentes ao SPKF, como X_0 , V e W , correspondentes à incerteza do estado inicial, sensor de tensão na equação de saída e sensor de corrente na equação de estado do SPKF.

A primeira função é a *initSPKF* utilizada apenas uma vez no início do algoritmo para criar as estruturas dos dados utilizados na implementação do SPKF. O primeiro bloco desta função definiu a corrente inicial do resistor de difusão, estado inicial da histerese, de carga e armazenou os valores na estimativa de estado X_{hat} . Em seguida, armazenou os valores de covariância do erro de estimativa do estado inicial do ruído do processo e do sensor, calculou o fator de *Cholesky* (raiz quadrada do ruído do processo) e os componentes de ruído do sensor da matriz de covariância de estado aumentado.

O segundo bloco, definiu o número de elementos no vetor de estado Nx , de medição Ny , de entrada do sistema Nu , do ruído do processo Nw , do ruído do sensor Nv e calculou o número de elementos no vetor de estado aumentado Na . Todos estes dados foram gerados pela função *initSPKF* e armazenados para acesso durante a rotina de execução da função *iterSPKF*.

De volta ao algoritmo principal foi dado início ao *loop for* que transcorreu sobre todos os dados do teste dinâmico e computou os valores de saída do SPKF. Para calcular os valores de estado e saída, utilizou-se a função *iterSPKF* que tem como entrada os valores medidos de tensão vk , corrente ik , temperatura definida Tk , intervalo de tempo de amostra Δt e a estrutura de dados definida anteriormente *spkfData*. A função retorna os valores zk que é o valor de SOC estimado, zk_{bnd} que são as bordas de erro definidas pela simulação e o *spkfData* que é a estrutura dos dados que foram utilizados.

O primeiro bloco desta função, extraiu os dados do modelo ESC para simular a célula e modificar a corrente de entrada aplicando o fator de Eficiência de Coulomb η . Na sequência o algoritmo iniciou os respectivos cálculos que definem o SPKF, calculou a estimativa de estado aumentado no tempo anterior e a matriz de incerteza correspondente.

O algorítimo segue calculando a matriz X_a que contém os pontos Σ aumentado, implementa a equação de estado em X_x , a estimativa da previsão de estado no momento em X_{hat} e a matriz de covariância de erro ΣX . A função *stateEqn* que retorna os valores a serem armazenados em X_x calcula os novos valores dos estados de corrente no resistor de difusão, a matriz de histerese h_k e o SOC z_k . A função *outputEqn* que retorna o valor a ser armazenado em Y tem como parâmetros de entrada X_{hat} que é uma matriz que contém em cada coluna os ponto sigma de estado previsto, corrente medida *current*, ruídos do sensor *ynoise*, temperatura escolhida do modelo *T* e os parâmetros do modelo *model*. A previsão de tensão y_{hat} é então calculada com base nos pontos sigma de entrada do modelo.

Seguiu-se com o passo seguinte, onde foi calculado a matriz de ganho L através da covariância cruzada ΣXY entre o erro de previsão de estado, a inovação e o somatório ponderado para a covariância da inovação ΣY . Na sequência, foi calculado a inovação ou medição residual r , verificado se não existe grande discrepância nos valores, para que possa detectar um erro de medição do sensor, caso dentro do limite e atualizada a previsão de estado X_{hat} , definido os limites superior e inferior da estimativa desejada é atualizada a matriz de covariância de erro de medição, de 5%. Por fim, foram armazenadas as informações necessárias para a próxima iteração e retornado o estimador de estado de carga zk com seus respectivos limites.

2.6 Indicadores de Performance do Piloto

Para caracterizar o modelo de pilotagem a partir do perfil UDDS (Figura 2.5), foram utilizados os dados de corrente da simulação dinâmica da célula A123. Apesar de não haver os dados do pedal de acelerador e freio do veículo, foi considerada uma relação linear com o pedal do acelerador no momento em que a corrente é positiva (descarga) e com o pedal de freio quando a corrente é negativa (regeneração, corrente de recarga) que pode ser observada na Figura 2.6 . Sendo assim, estes dados foram usados no cálculo dos KPIs, que caracterizam um modelo de pilotagem da simulação utilizada.

O diagrama de blocos do processo, incluindo a obtenção do KPI através dos dados

UDDS é representado a seguir (Figura 2.4):

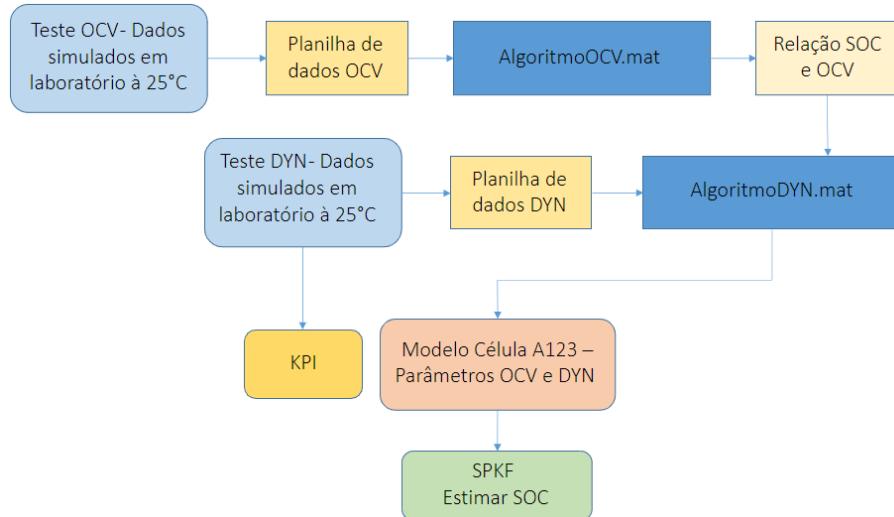


Figura 2.4 – Fluxograma Geral - Incluindo KPI

O algoritmo KPIDYN foi desenvolvido no software *MatLab* para calcular os KPIs a partir dos dados de simulação. O primeiro passo foi inicializar o sistema, carregando os dados e parametrizando as variáveis que seriam utilizadas e, em seguida, extraídos os sinais de Freio (*Brake*) e Acelerador (*Throttle*) do sinal UDDS a partir da função signals. As Figuras 2.5 e 2.6 demonstram ambos os gráficos gerados.

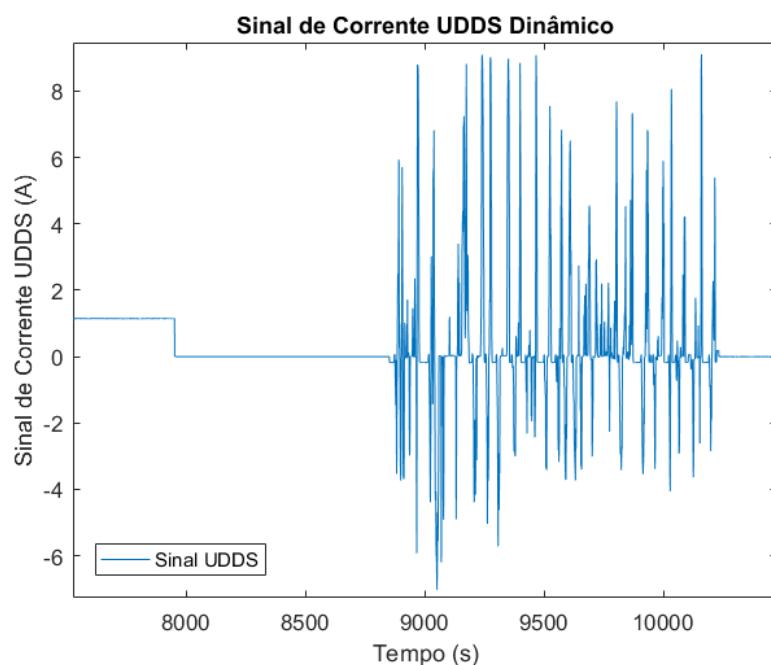


Figura 2.5 – Sinal de Corrente do perfil UDDS

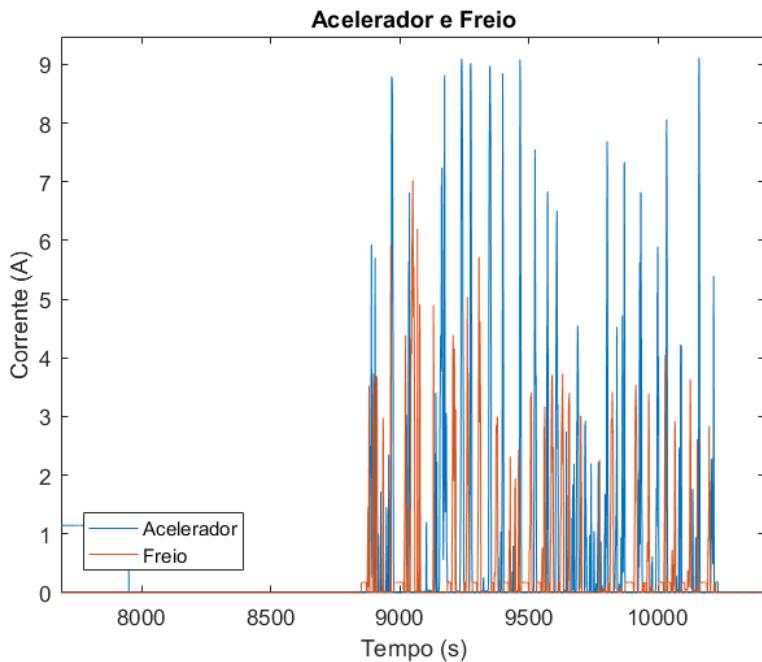


Figura 2.6 – Sinais de Freio e Acelerador do perfil UDDS

2.6.1 Agressividade e velocidade no pedal de freio

Com os dados exclusivos referentes ao pedal de freio foram calculados os parâmetros de agressividade de freio (*Brake Aggression*) e liberação do pedal de freio (*Brake Release*) em 5 passos:

1. Derivar o sinal de freio para calcular o parâmetro referente a velocidade do pedal de freio (Figura 2.7).
2. Aplicar *gates* para filtrar o sinal nos pontos de interesse relativos a liberação do pedal (Figura 2.8).
3. Aplicar *gates* para filtrar o sinal nos pontos de interesse relativos a agressividade do freio (Figura 2.9).
4. Calcular a média acumulada do sinal da liberação do pedal para transformá-lo em um KPI.
5. Calcular a média acumulada do sinal da agressividade de freio para transformá-lo em um KPI.

Os parâmetros dos *gates* foram escolhidos para melhor ajuste na filtragem do sinal e geração dos sinais dos KPIs de liberação e agressividade do pedal de freio (Figura 2.10).

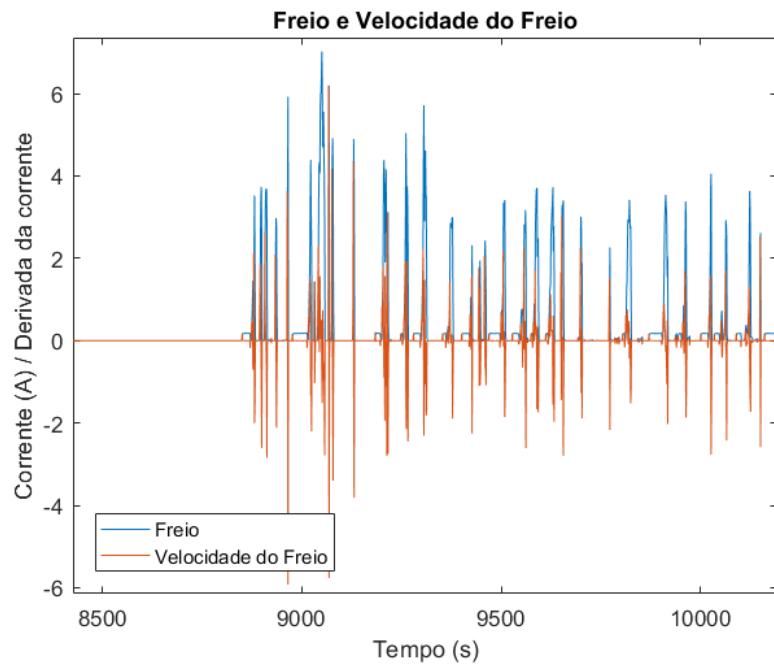


Figura 2.7 – Velocidade do Freio

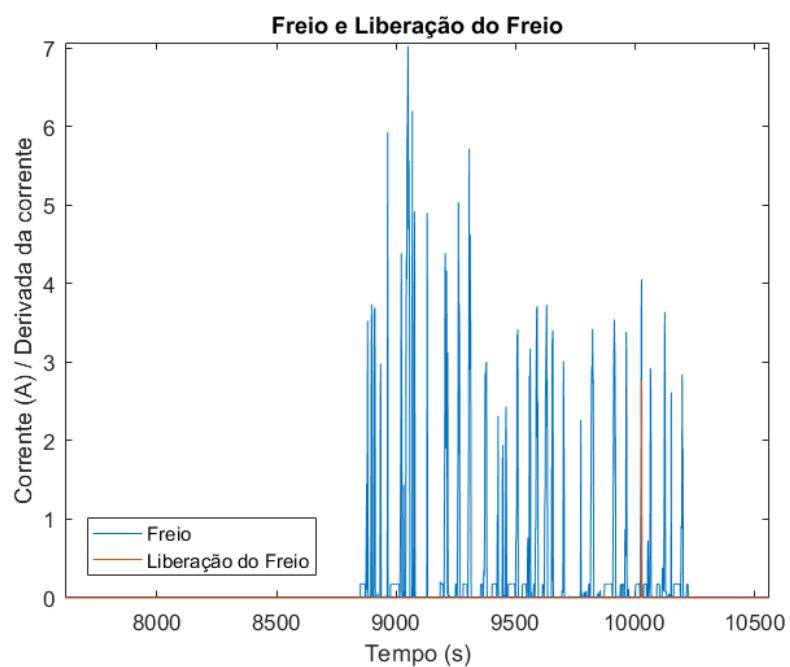


Figura 2.8 – Liberação do Freio

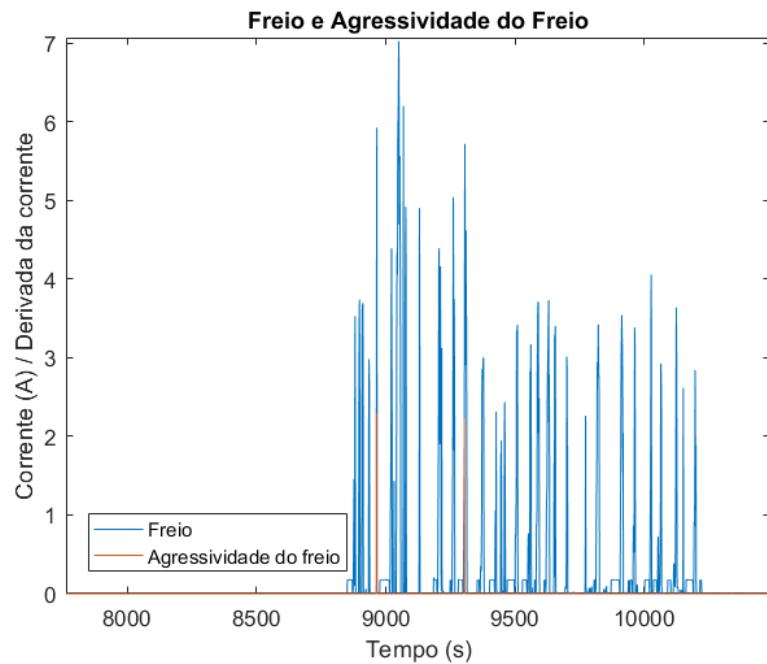


Figura 2.9 – Agressividade do Freio

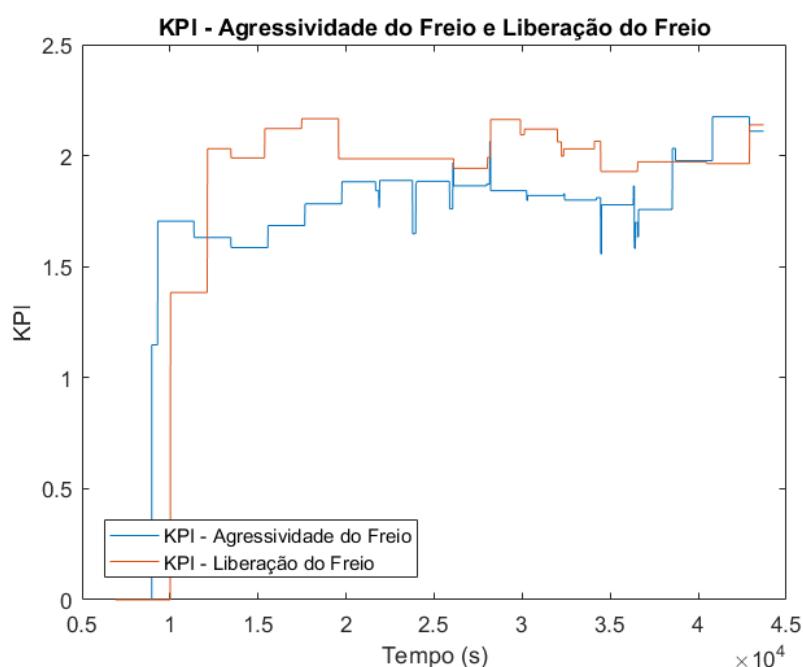


Figura 2.10 – KPI do Freio

2.6.2 Agressividade e velocidade no pedal do acelerador

Da mesma forma como feito com o sinal de freio, foram calculados os parâmetros agressividade do acelerador (*Throttle Aggression*) e liberação do pedal do acelerador (*Throttle Release*) com os dados exclusivos do acelerador, em 5 passos:

1. Derivar o sinal de acelerador para calcular o parâmetro referente a velocidade do pedal do acelerador (Figura 2.11).
2. Aplicar *gates* para filtrar o sinal nos pontos de interesse relativos a liberação do pedal do acelerador (Figura 2.12).
3. Aplicar *gates* para filtrar o sinal nos pontos de interesse relativos a agressividade do acelerador (Figura 2.13).
4. Calcular a média acumulada do sinal da liberação do pedal do acelerador para transformá-lo em um KPI.
5. Calcular a média acumulada do sinal da agressividade do acelerador para transformá-lo em um KPI.

Novamente, os parâmetros dos gates foram escolhidos para melhor ajuste na filtragem do sinal e geração dos sinais dos KPIs de agressividade e liberação do acelerador (Figura 2.14).

Com os dados de KPIs calculados, obteve-se uma característica intrínseca da pilotagem oriunda dos dados UDDS. Sendo assim, otimizar o resultado do SOC estimado com o real, utilizando o SOC calculado pelo SPKF e os quatro parâmetros de KPIs para alimentar uma RNA profunda que foi treinada para estimar o SOC baseado nestes dados de entrada.

2.7 Rede Neural de Aprendizagem Profunda

Uma RNA totalmente conectada (*Fully Connected*) foi desenvolvida em *Python* para estimar o SOC da célula A123 baseado nos dados do SPKF e dos KPIs. O desenvolvimento da RNA utilizou a biblioteca *Pytorch*, desenvolvida pelo *Facebook*, além da biblioteca *Numpy* e funções específicas para aplicação de redes neurais.

O diagrama de blocos do processo, incluindo a obtenção do SOC final, é demonstrado na (Figura 2.15):

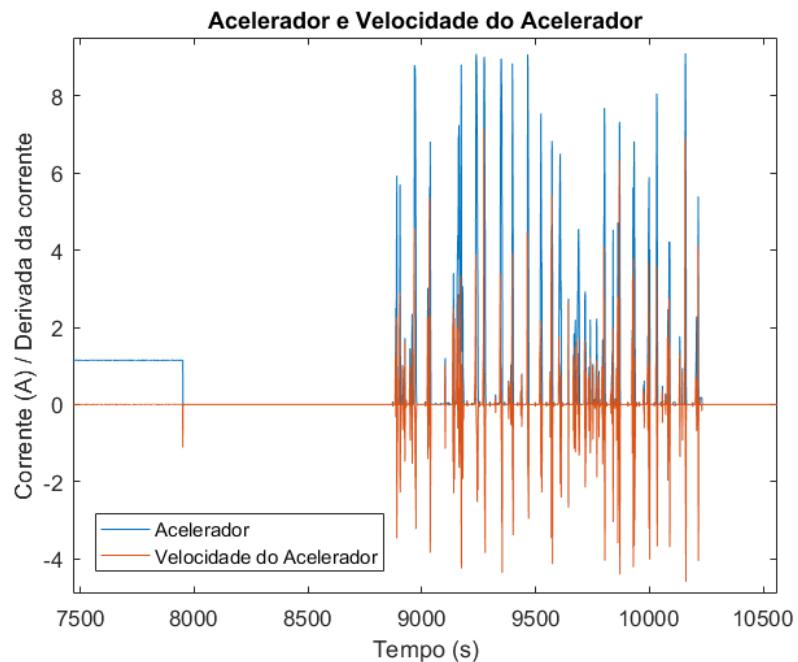


Figura 2.11 – Velocidade do Acelerador

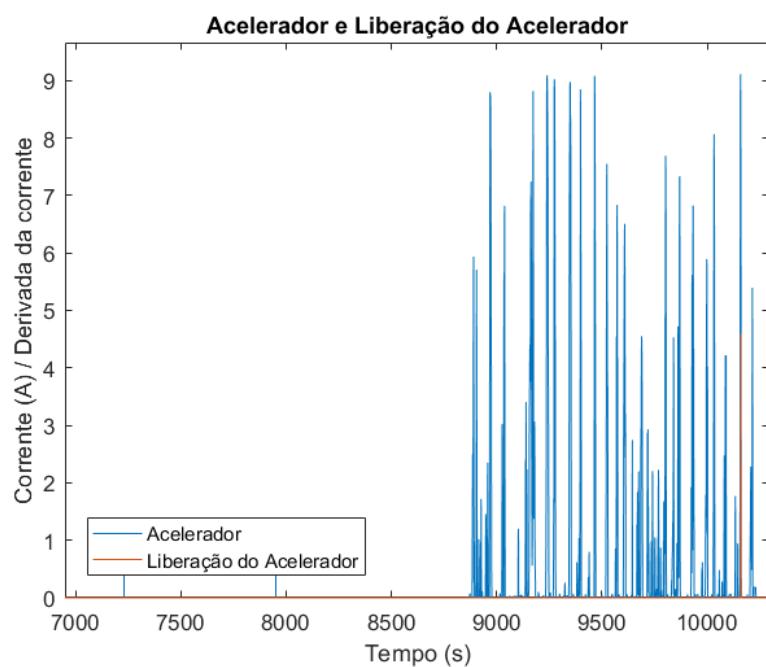


Figura 2.12 – Liberação do Acelerador

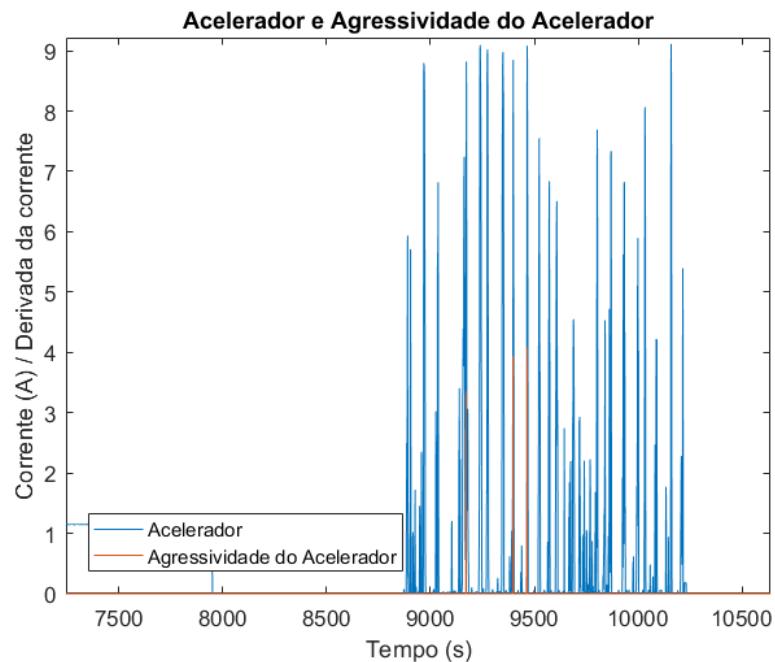


Figura 2.13 – Agressividade do Acelerador

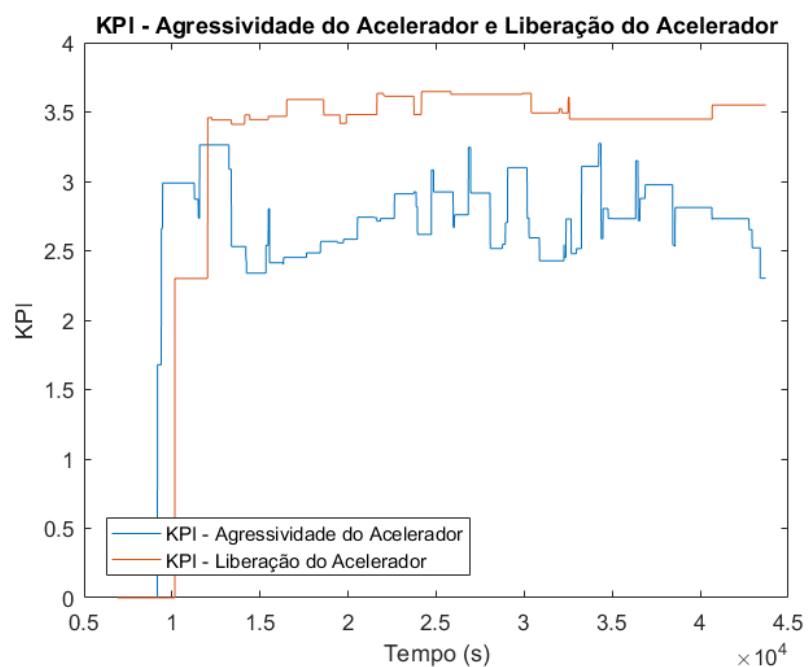


Figura 2.14 – KPI do Acelerador

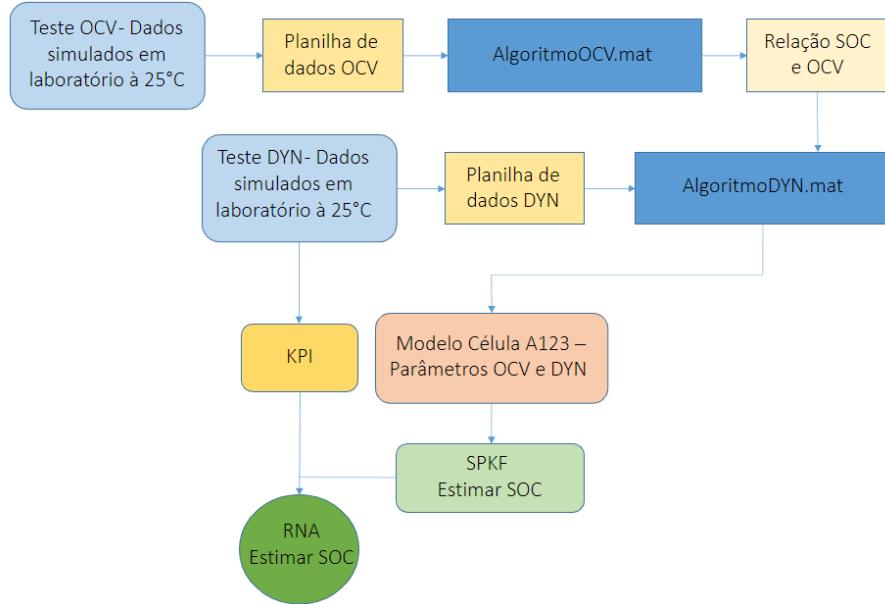


Figura 2.15 – Fluxograma Geral Final

Primeiramente, os dados foram organizados e normalizados em uma tabela de *Excel* para serem salvos em arquivos de texto *.txt* e importados pelo algoritmo em *Python*. A matriz de entrada para os dados de treinamento *Xtrain* contém as informações de SOC calculada pelo SPKF, Indicador de Performance da Agressividade do Freio (*KPI Brake Aggression*), Indicador de Performance da Liberação do Pedal de Freio (*KPI Brake Release*), Indicador de Performance da Agressividade do Acelerador (*KPI Throttle Aggression*) e Indicador de Performance da Liberação do Pedal de Acelerador (*KPI Throttle Release*) nas colunas 0, 1, 2, 3 e 4 respectivamente, relativo aos dados dinâmicos da célula A123 simulados aplicando o perfil de corrente UDDS. Os dados de resposta do treinamento *ytrain* contém o SOC real, o mesmo utilizado para validar o SPKF. Os dados utilizados para o teste foram variados para poder testar o desempenho da RNA para diferentes situações, todas dentro de possíveis variações de aplicação *Motorsports*.

3 RESULTADOS E COMENTÁRIOS

3.1 Teste 1: Tensão de Circuito Aberto

Os parâmetros de tensão da célula extraídos do teste foram $V_{min} = 2\text{ V}$ e $V_{max} = 3.75\text{ V}$. Os testes foram feitos para temperaturas de -25°C à 45°C (Figura 3.1) e o modelo desenvolvido utilizou os dados de 35°C , por se assemelhar ao caso real de aplicação. Foi observado também que a maior não linearidade ocorre principalmente em temperaturas menores do que 0°C , mas esta não contemplada os casos de aplicação do nosso problema de interesse. Os resultados dos passos do teste descrito na Metodologia podem ser analisados em (Nas Figuras 3.2 e 3.3).

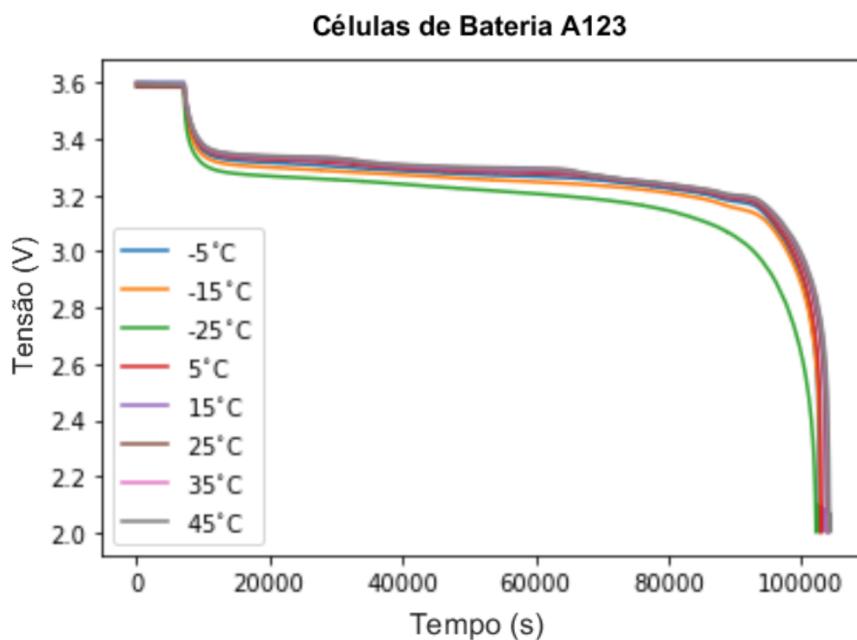


Figura 3.1 – Tensão [V] nos passos 1 e 2 para todas as temperaturas.

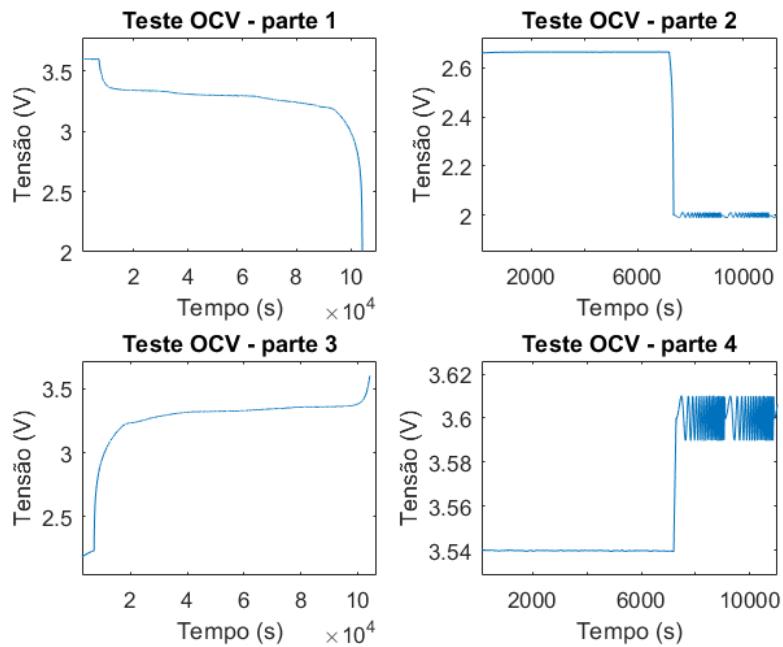


Figura 3.2 – OCV - A123 à 35°C

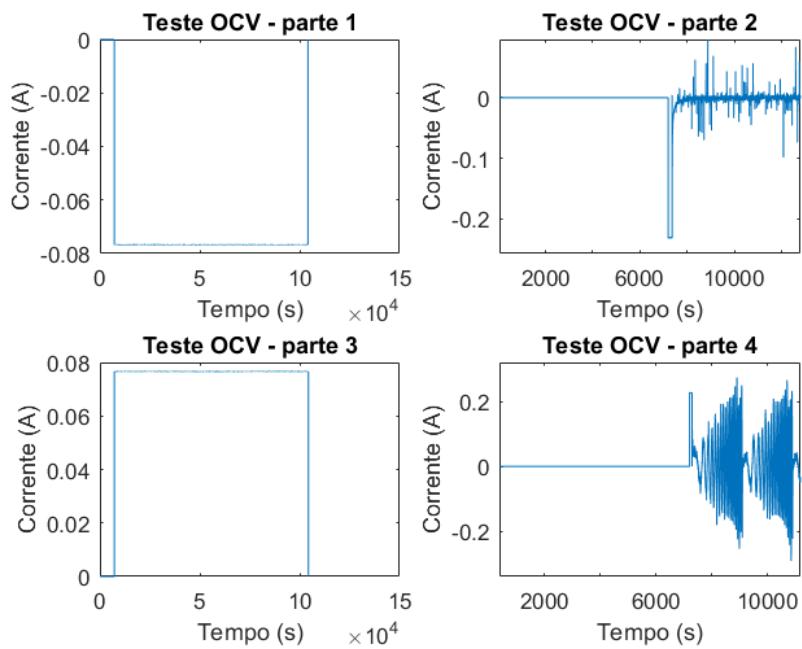


Figura 3.3 – OCV - A123 à 35°C

3.2 Teste 2: Perfil Dinâmico de Carga e Descarga

Os parâmetros de tensão da célula extraídos do teste foram $V_{min} = 2$ V e $V_{max} = 3.75$ V. Novamente os testes foram feitos para temperaturas de -25°C à 45°C para a célula A123 e os dados de tensão (Figura 3.4) e corrente (Figura 3.5) à 35°C foram utilizados como dados de entrada do algoritmo que irá obter os parâmetros dinâmicos do modelo ESC.

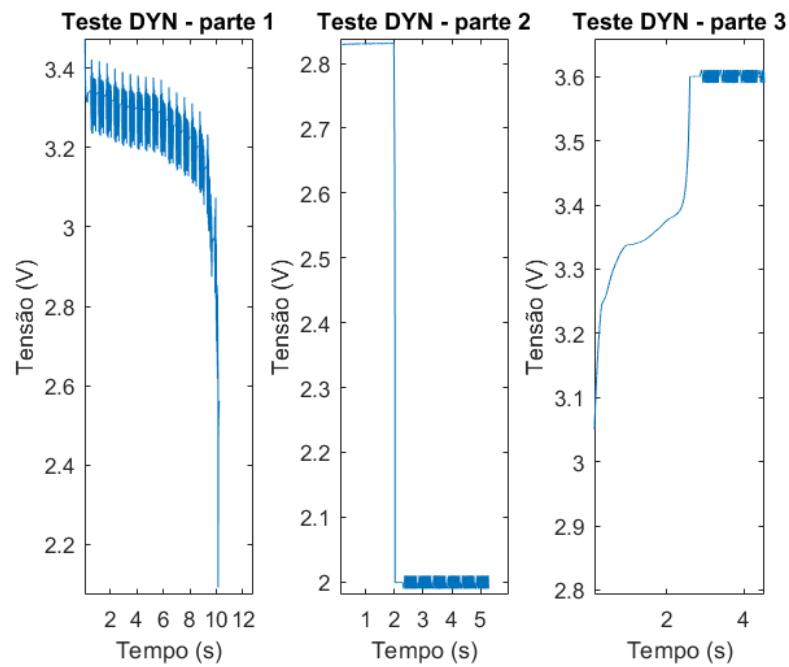


Figura 3.4 – DYN - A123 à 35°C

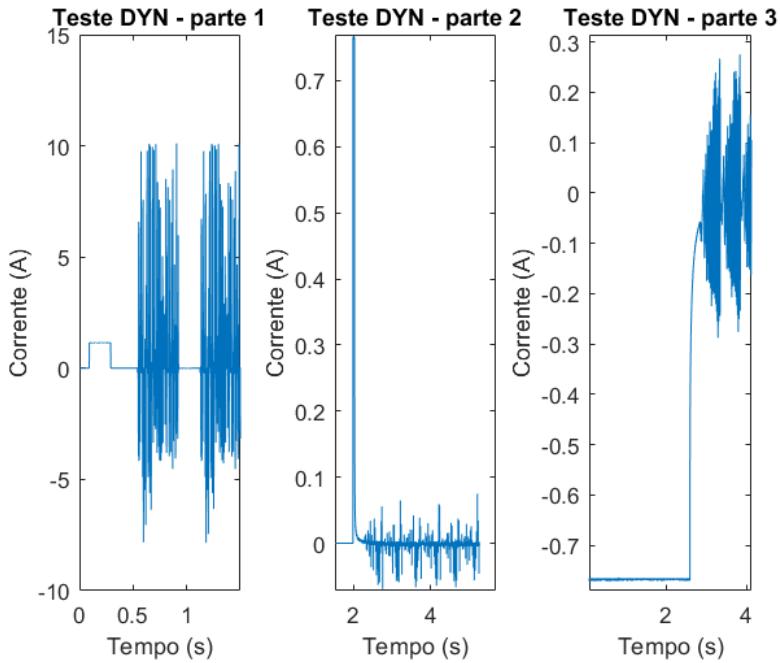


Figura 3.5 – DYN - A123 à 35°C

3.3 Algoritmo da Tensão de Circuito Aberto

Antes de iniciar o algoritmo foi necessário um pré processamento dos dados extraídos do teste laboratorial separando cada passo do processo em dados de tempo(s), passo, corrente (A), tensão (V), corrente de descarga (Ah) e corrente de carga (Ah). Após o tratamento dos dados, o algoritmo é iniciado inserindo a somatória dos valores de corrente de descarga e carga para calcular a Eficiência de Coulomb η . Com o valor de η o próximo passo foi calcular a capacidade total da célula, multiplicando a eficiência η na corrente de carga e fazendo a subtração da somatória da corrente de descarga com a corrente de carga, como mostra a equação 2.5.

O R_0 foi calculado obtendo a variação de tensão no início da carga e descarga. Este cálculo foi feito subtraindo a tensão imediatamente antes do início da descarga a primeira tensão após a descarga, consequentemente o mesmo processo para a carga. Em seguida, foi obtido um valor de tensão considerando o efeito do R_0 , sendo subtraído seu efeito durante a carga e somado durante a descarga para calcular o valor do SOC. Com os valores compensados de SOC e OCV foi possível estabelecer uma relação entre eles que foi utilizada na sequência do desenvolvimento do algoritmo para calcular os parâmetros dinâmicos a partir do perfil UDDS. Em resumo, o código calculou primeiro a eficiência η , ajustou as curvas de carga e descarga compensando o valor da resistência interna R_0 e compilou as relações de SOC e OCV.

3.4 Algoritmo do Teste Dinâmico

Os gráficos gerados pelo algoritmo apresentaram a estimativa de tensão da célula com um RMSE=15.85 mV. Com os resultados obtidos através dos algoritmos dos testes 1 e 2, a matriz de dados do modelo ESC para a célula A123 de entrada para o FK estava preparada para ser utilizada.

3.5 Filtro de Kalman Ponto Sigma

Os resultados simulados do algoritmo SPKF com os dados do modelo ESC e perfil de corrente UDDS geraram a primeira estimativa de SOC (Figura 3.6), que é o principal objetivo deste trabalho.

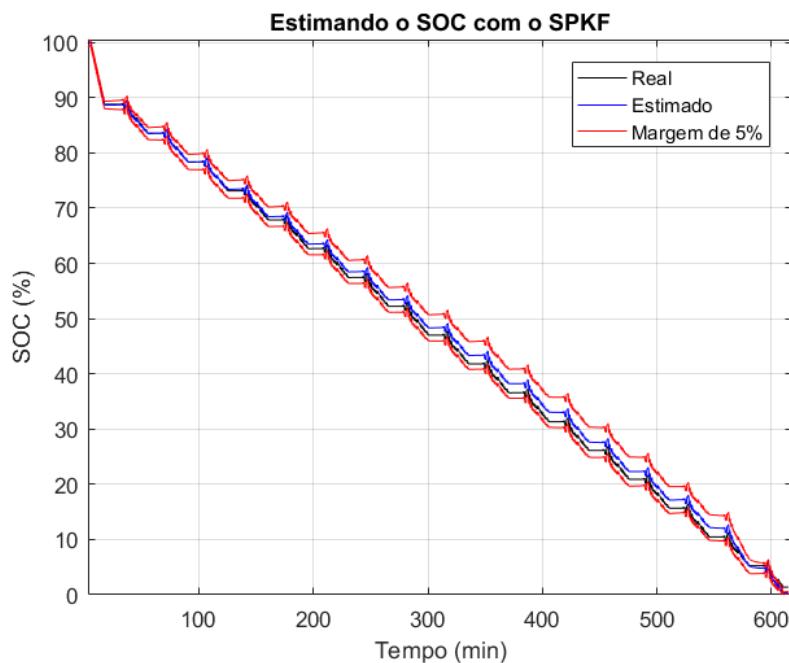


Figura 3.6 – Estimativa SOC SPKF

O resultado obteve um RMSE= 1.11% e 1.93% de tempo fora da borda delimitada de 5% de erro (Figura 3.7).

Embora o resultado deste algoritmo seja bom em comparação a outros métodos e dentro de uma margem de erro aceitável, a continuação deste trabalho irá propor uma nova maneira de melhorar a precisão dos cálculos utilizando uma abordagem específica para a aplicação em *Motorsports*. O objetivo é melhorar a precisão principalmente para valores de baixo SOC (Figura 3.8) onde na prática serão os momentos mais importantes durante uma corrida, além de incluir uma personificação do piloto no algoritmo.

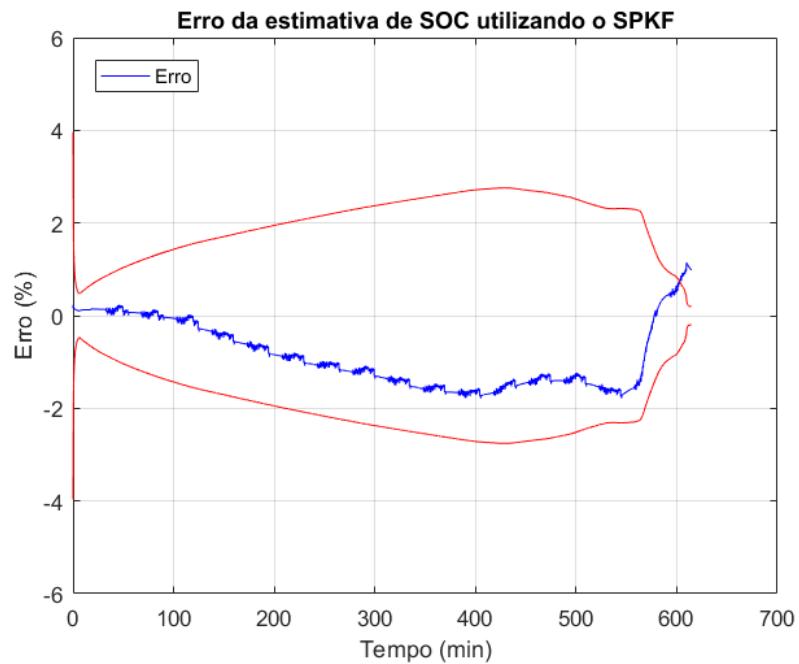


Figura 3.7 – Erro SPKF

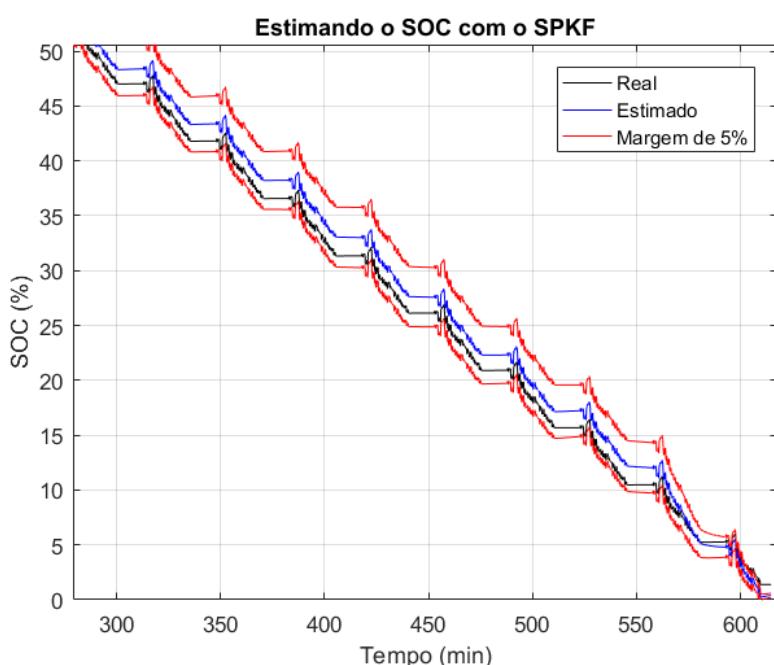


Figura 3.8 – Estimativa SOC SPKF < 50%

3.6 Rede Neural de Aprendizagem Profunda

A técnica de separação dos dados em lotes foi aplicada para melhorar o desempenho do algoritmo, o modelo da RNA profunda foi definido como sequencial e as funções de ativação utilizadas foram *Hardtanh* (variação da tangente hiperbólica) e Unidade Exponencial Linear (*Exponential Linear Unit - ELU*)

As funções *trainmodel* e *runeepoch* foram criadas para serem executadas durante o treinamento e teste da RNA. O otimizador escolhido foi o Gradiente Descendente Estocástico (*Stochastic Gradient Descent*) e os parâmetros de perda (*loss*), acurácia (*accuracy*) e erro (*error*) são calculados a cada época durante o treinamento, baseado no valor estimado de SOC pela RNA. A função *runeepoch* é responsável por inserir os dados no modelo sequencial, obter a resposta do SOC estimado e retornar os valores médios de erro (*error*) e acurácia (*accuracy*). Com esse algoritmo foi possível calcular os valores estimados de SOC.

Os primeiros resultados foram gerados com os dados de teste e treinamento à 35°C. Estes dados foram os mesmos utilizados para obtenção do SOC pelo SPKF e geração de KPI. Como relatado na Sessão anterior, o SPKF obteve boa precisão, com um RMSE= 1,1 % e uma percentagem de 1,93% de tempo fora da borda delimitada de 5% de erro para mais ou para menos.

A RNA desenvolvida apresenta os seguintes hiper parâmetros:

- Quantidade de camadas ocultas
- Quantidade de neurônios nas camadas ocultas
- Função de ativação de cada neurônio
- Taxa de aprendizado
- Tamanho dos agrupamentos que dividirá os dados de treinamento
- Quantidade de épocas de treinamento

E os parâmetros de avaliação de desempenho de avaliação serão:

- Acurácia: Representará o quanto os dados estimados estão dentro da borda delimitada de 5% de erro para mais ou para menos

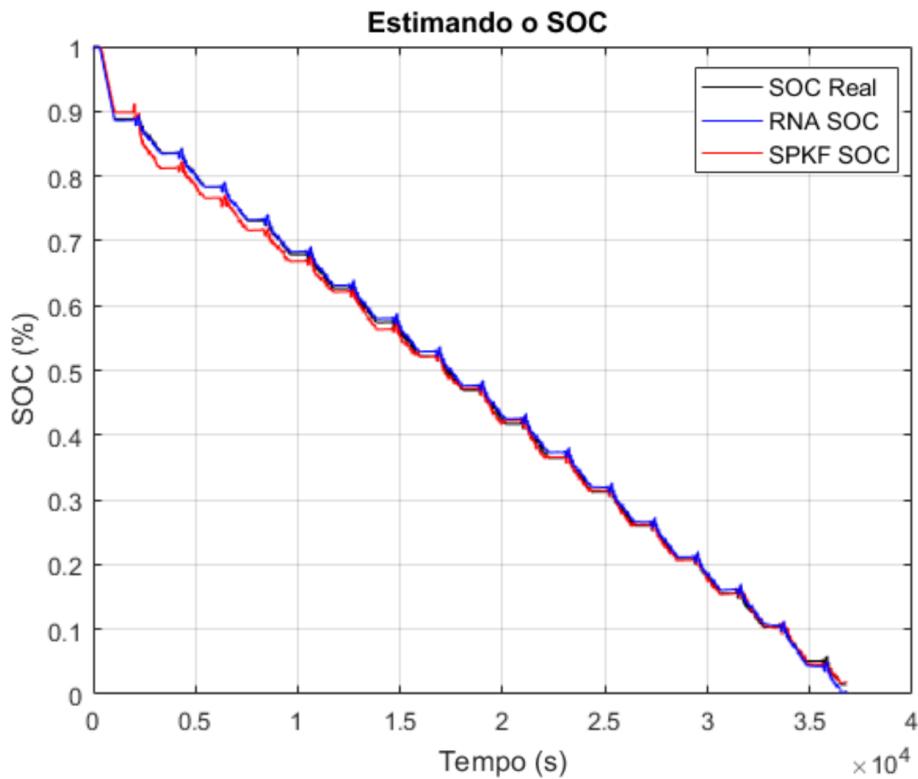


Figura 3.9 – Resultado da estimativa do SOC pelos modelos

- Erro: Mede o erro quadrado médio, norma L2 ao quadrado, entre cada elemento na entrada (SOC estimado) e o destino (SOC real)

O resultado da simulação pode ser analisado na Figura 3.9 e a RNA simulada teve a configuração indicada na Tabela 3.1.

Tabela 3.1 – Configuração Rede Neural

Hiperparâmetro	Valor
Camadas ocultas	2
Neurônios por camada	10
Função de ativação	ELU
Taxa de aprendizado	0.01
Agrupamentos de treinamento	8
Épocas de treinamento	100

O modelo para 35°C apresentou uma avaliação de acurácia= 97.91% e erro= 0.0027% enquanto o SPKF apresentou uma acurácia= 92.28% e um erro= 0.0029%. O resultado apresentado pelo SPKF também apontou que o erro da estimativa de SOC foi maior nos valores finais, onde a não linearidade dos dados era mais evidenciada e o resultado estimado apresentou o maior desvio em relação ao valor real de SOC. Porém o modelo com a RNA obteve maior

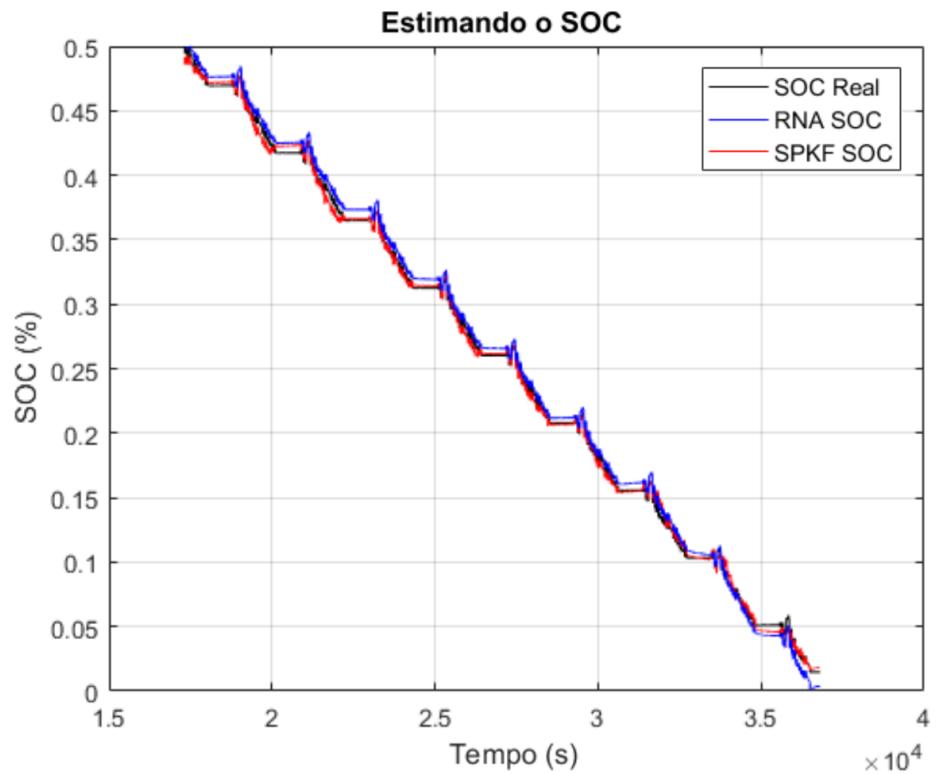


Figura 3.10 – Resultado da estimativa dos modelos com SOC menor que 50%

precisão no cálculo em relação ao SPKF para valores menores de SOC como pode ser visto nas Figuras 3.10 e 3.11 para SOC menor que 50% e 20%, respectivamente.

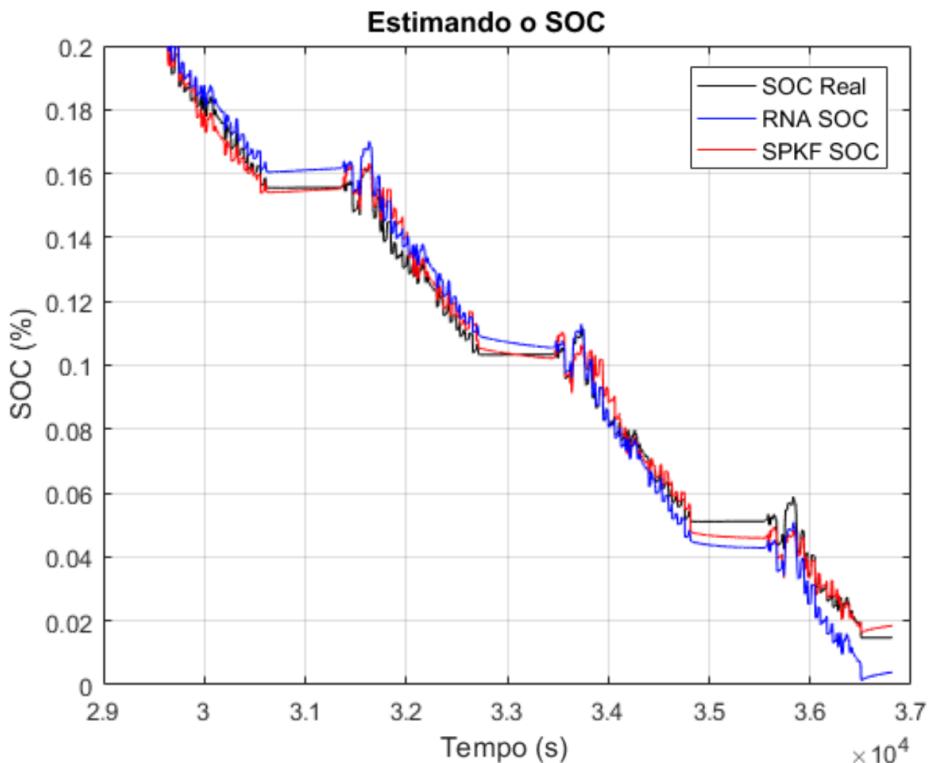


Figura 3.11 – Resultado da estimativa dos modelos com SOC menor que 20%

3.7 Validação da RNA

Após demonstrar um bom desempenho quando utilizamos os dados de treinamento como teste da RNA e definimos as melhores configurações de hiper parâmetros para cada temperatura de teste, vamos testar o desempenho para dados diferentes de treinamento e validação.

Foram utilizados 2 tipos de perfis de carga e descarga da bateria, um representando características de pilotagem urbana (UDDS) na Figura 3.12 e o de direção urbana federal (FUDS) na Figura 3.13. Na sessão anterior, o perfil UDDS foi utilizado tanto nos dados de treinamento como nos dados de validação, nesta sessão vamos apresentar os resultados simulando perfis diferentes do utilizado durante o treinamento, situação muito mais próxima à aplicação real em *Motorsports*.

Foi utilizado um banco de dados disponibilizado pelo CALCE que utiliza um perfil FUDS para descarregar uma bateria de Lítio modelo A123. Como o modelo é o mesmo que foi utilizado durante este trabalho na obtenção dos parâmetros internos, este perfil é compatível com o modelo desenvolvido.

A RNA apresentou uma avaliação de acurácia= 100% e erro= 0.0052% com uma configuração de parâmetros listada na Tabela 3.2.

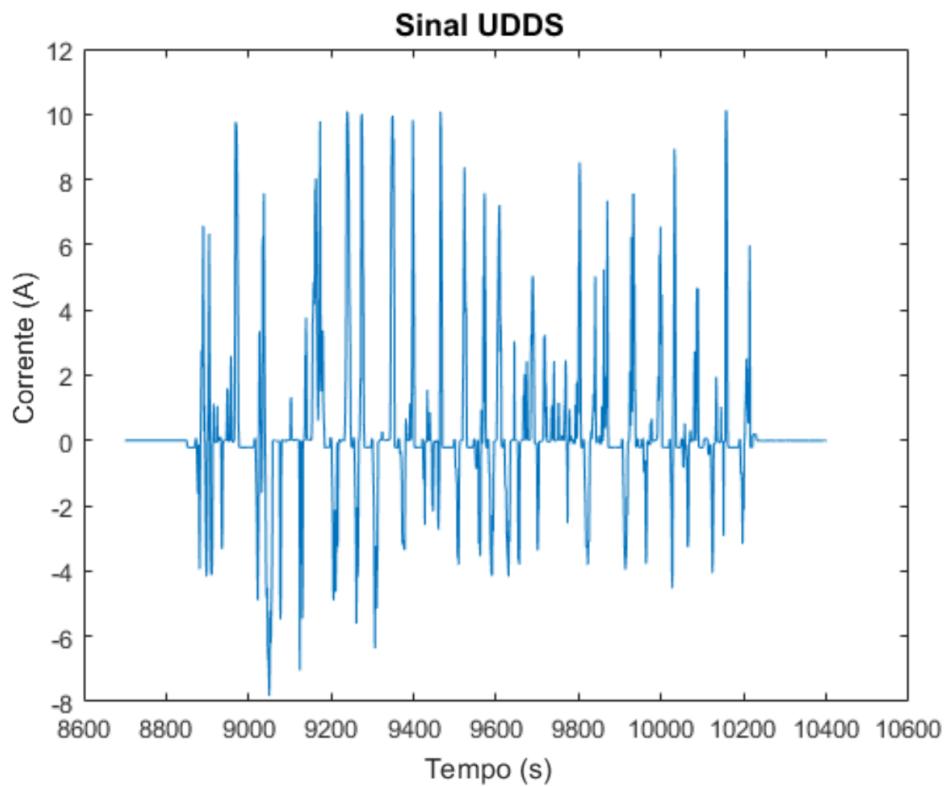


Figura 3.12 – Sinal UDDS

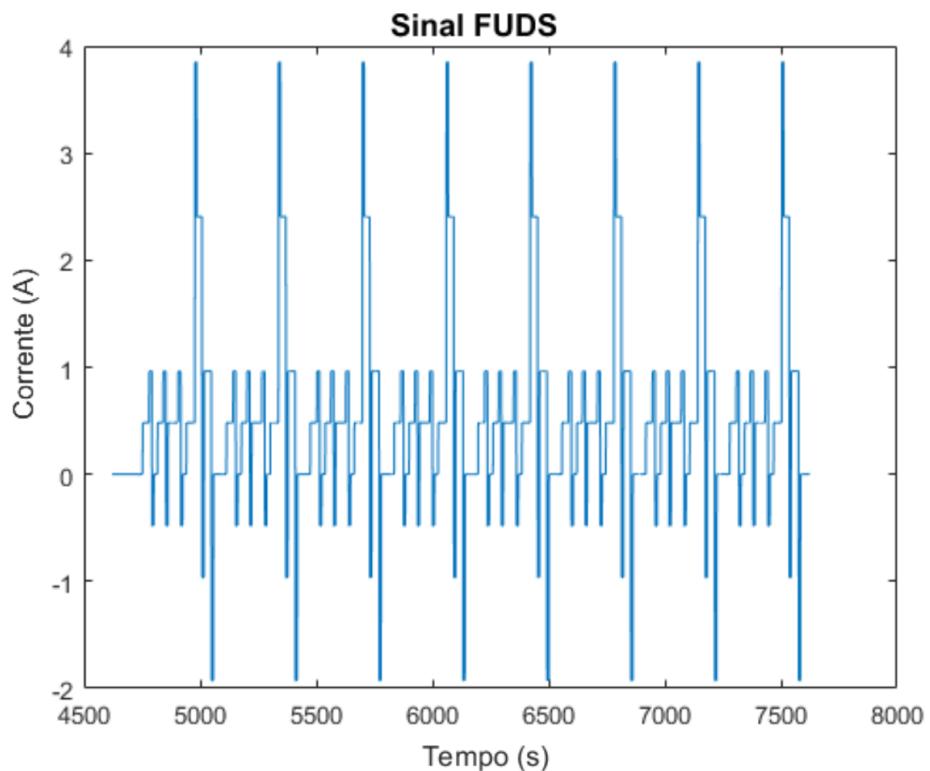


Figura 3.13 – Sinal FUDS

Tabela 3.2 – Configuração Rede Neural

Hiperparâmetro	Valor
Camadas ocultas	1
Neurônios por camada	100
Função de ativação	Hardtanh
Taxa de aprendizado	0.1
Agrupamentos de treinamento	128
Épocas de treinamento	100

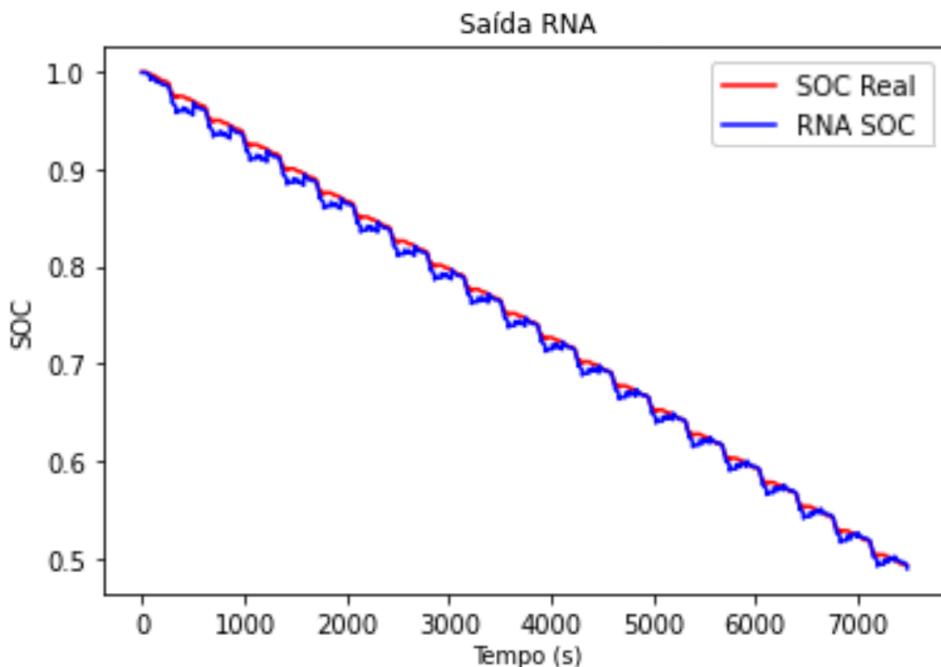


Figura 3.14 – Resultado Rede Neural Perfil FUDS - 35°C

Os resultados apresentados pela Figura 3.14 mostraram que a variação mais abrupta dos KPIs (Figuras 3.15 e 3.16) para este perfil de carga/descarga FUDS impactavam mais negativamente no valor estimado de SOC da RNA. O que é evidenciado quando plotamos a função de erro da simulação (Figura 3.17).

Para melhorar a resposta da RNA observamos que seria necessário suavizar as variações do KPI, aplicando o cálculo da média móvel para cada ciclo FUDS em substituição ao método que considerava a média apenas do valor atual n e o valor passado mais próximo $n - 1$. Desta forma foi possível minimizar a variação do KPI durante cada ciclo e ainda sim manter as singularidades de valores médios entre pilotos com características diferentes de pilotagem, preservando o objetivo e a importância da sua utilização. Nas Figuras 3.18 e 3.19 podemos observar os novos sinais de KPI com a média móvel total aplicada. O novo resultado (Figura 3.20) mostrou que esta técnica melhorou a resposta da estimativa de SOC da RNA e reduziu o efeito

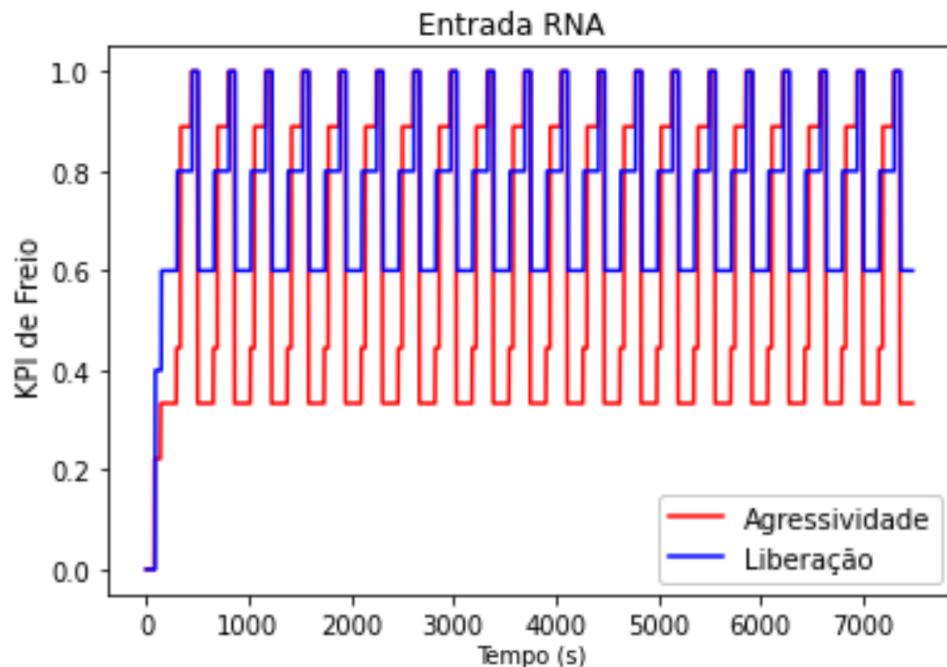


Figura 3.15 – Sinal FUDS - KPI de freio

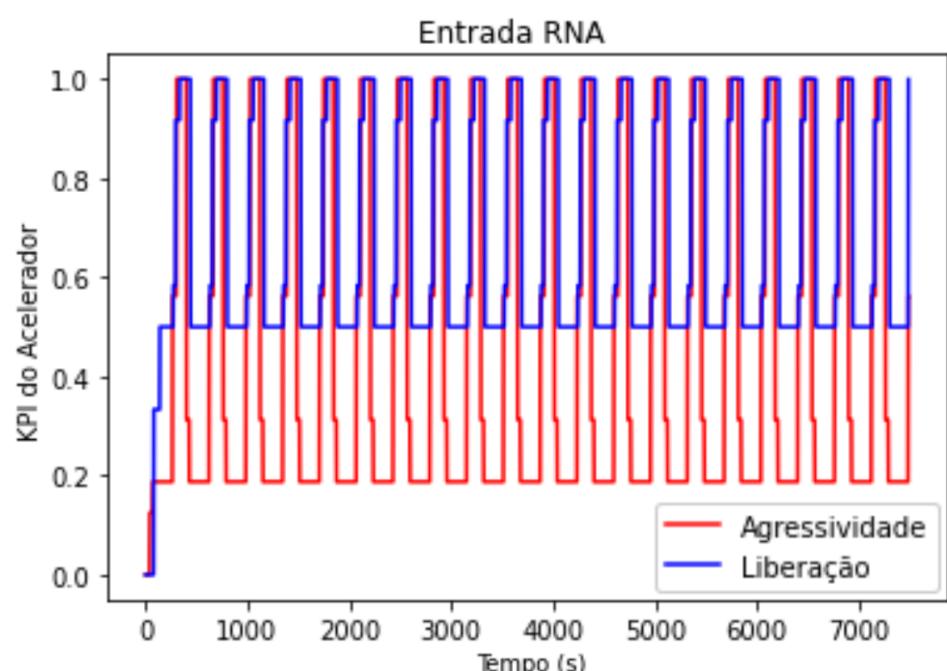


Figura 3.16 – Sinal FUDS - KPI do acelerador

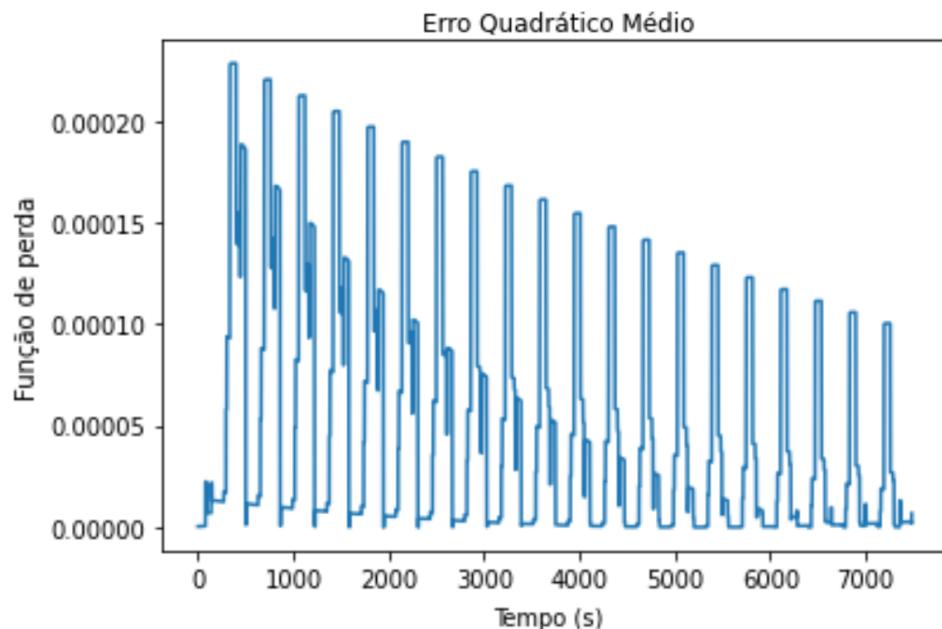


Figura 3.17 – Função de perda para o sinal FUDS à 35°C

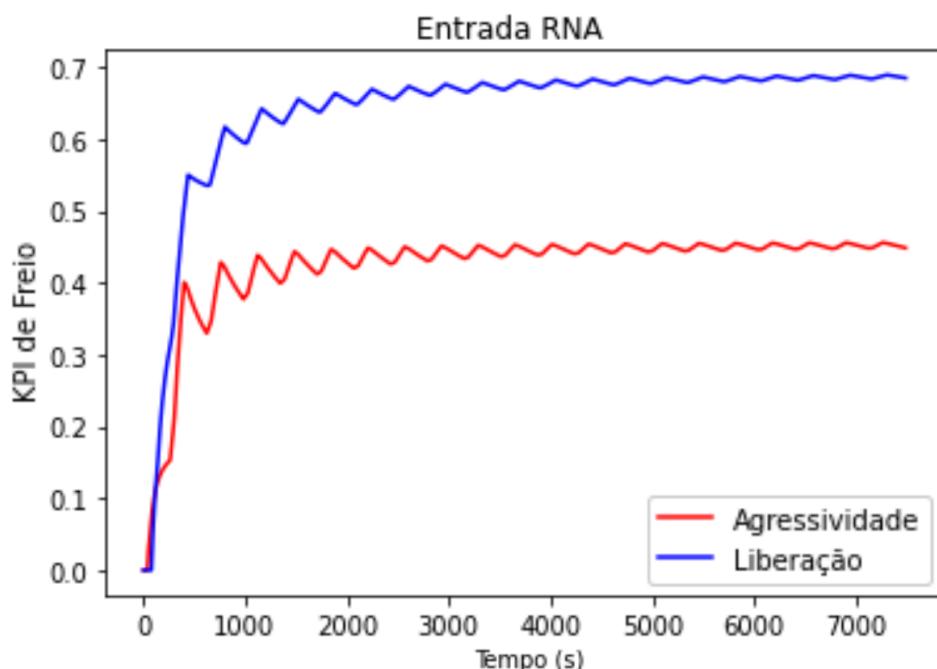


Figura 3.18 – Sinal FUDS - KPI de freio com média móvel

da variação do KPI no erro do modelo (Figura 3.21).

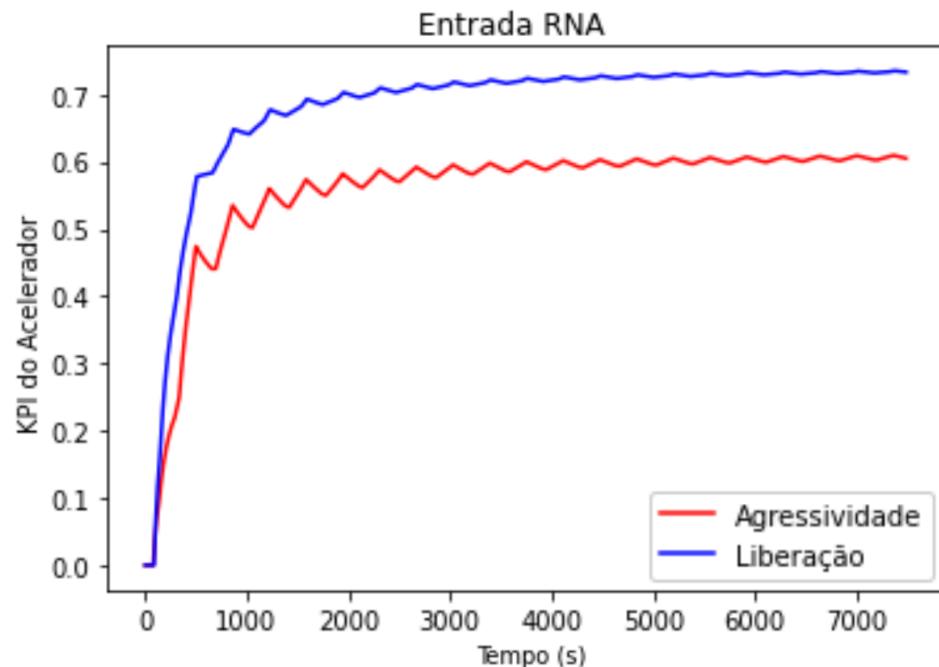


Figura 3.19 – Sinal FUDS - KPI do acelerador com média móvel

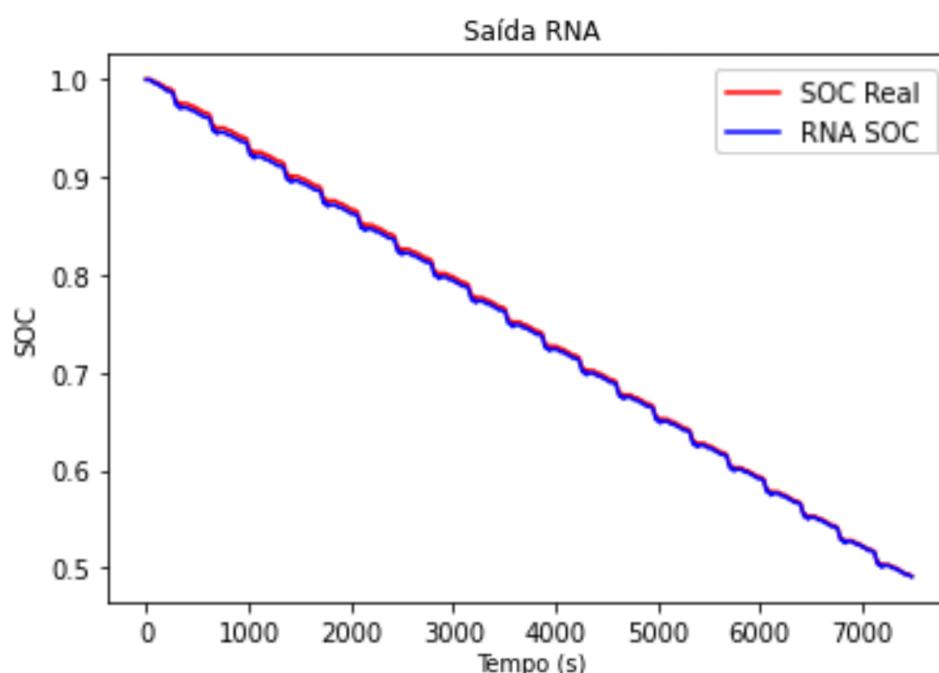


Figura 3.20 – Resultado da RNA com perfil FUDS e KPI com média móvel à 35°C

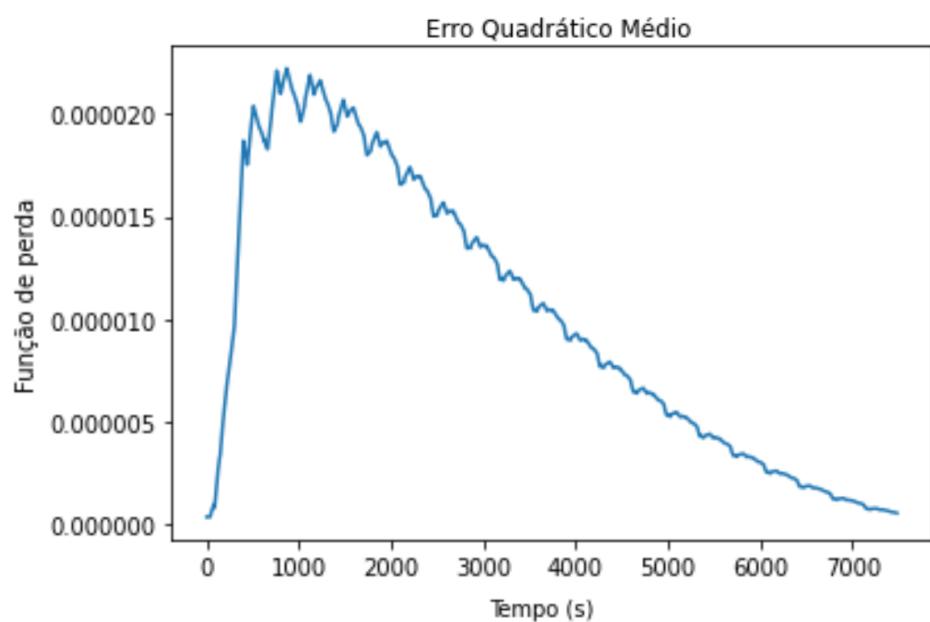


Figura 3.21 – Função de perda para o sinal FUDS e KPI com média móvel à 35°C

4 CONCLUSÃO

Podemos concluir que o modelo proposto, o Filtro de Kalman Ponto Sigma integrado a uma Rede Neural Artificial Profunda de um modelo parametrizado por Indicadores de Performance de um piloto, obteve resultados que demonstram que a linha de raciocínio adotado pode continuar a ser desenvolvida para aplicações específicas de *Motorsports*. Observamos que ao incluir os parâmetros intrínsecos a aplicação o algoritmo ganha maior robustez e precisão para a estimativa do Estado de Carga da Bateria. Atualmente temos modelos muito desenvolvidos na área eletroquímica, de modelos de circuitos equivalentes e também dos algoritmos baseados em dados como o Filtro de Kalman e Rede Neural, mas é raro encontrar estudos incluindo parâmetros específicos da aplicação do problema. Este desenvolvimento mostrou um bom potencial nos modelos simulados e indica que devemos continuar investindo em pesquisas neste sentido, não somente para este exemplo, mas para muitas aplicações onde modelos híbridos baseados em teoria e aplicação podem evoluir o desempenho do algoritmo. A utilização da expertise da aplicação real em conjunto com um modelo eficaz ao extrair os parâmetros da bateria e estimar o SOC poderá levar a excelência de performance do algoritmo para a aplicação embarcada. Os resultados demonstram que existe um vasto campo de pesquisa que pode aprimorar os métodos de estimar o SOC de uma Bateria de Lítio e ajudar a desenvolver e implementar novas tecnologias.

5 TRABALHOS FUTUROS

Os métodos híbridos apresentaram o maior potencial de desenvolvimento de todos os métodos estudados durante este trabalho. A fusão de conceitos físicos e químicos através de equações diferenciais e uma grande quantidade de dados simulados fornecidos ao modelo pode trazer muitos benefícios de desempenho ao algoritmo. Os métodos teóricos baseado nas equações trazem maior capacidade de solucionar diferentes tipos de problemas em condições muito diferentes, o que é uma desvantagem dos métodos orientados a dados que costumam ter um bom desempenho apenas para dados com características semelhantes aos que foram utilizados durante o treinamento. Em contra partida, os métodos orientados a dados são mais eficientes para obter uma resposta do problema, sendo mais recomendados para aplicações embarcadas. Poder unificar esses métodos utilizando suas características positivas para melhorarem o desempenho final do modelo é uma área de pesquisa que acreditamos que possa ser o futuro das questões aplicadas a obtenção de parâmetros de saúde de uma célula de bateria. Por isso um modelo híbrido que contenha a densidade de informação expressa por equações diferenciais de um modelo eletroquímico, juntamente com uma grande quantidade de dados de treinamento disponíveis pelos métodos de simulação em laboratório é um potencial caminho de desenvolvimento futuro.

Outro ponto importante a ser considerado é a utilização de expertise da aplicação prática do problema no modelo proposto, assim como neste presente trabalho. A grande maioria dos estudos está focada, por exemplo, em aprimorar os algoritmos de estimativa de estados ou modelos equivalentes que representem melhor a dinâmica de uma bateria. Isso é correto conceitualmente para aprimorar o desempenho dos métodos propostos, porém ainda é necessário adicionar parâmetros intrínsecos ao problema de aplicação. Este tipo de variável relaciona condições que somente serão apresentadas durante a aplicação do método, mas que estão diretamente relacionadas com o resultado estimado do problema. Em *Motorsports* existem muitos fatores que podem ser adicionados a solução do problema de obtenção da estimativa de SOC da bateria. Além dos KPIs apresentados, um fator que não foi incluso no método e que está relacionado é o desgaste de pneu. Ele está diretamente relacionado com o desempenho do veículo durante a corrida, velocidades mínimas e capacidade de tração em curvas, o que está diretamente relacionado com a quantidade de acelerador que será solicitado pelo piloto ao sistema de trem

de força alimentado pelas baterias. Além de influenciar no cálculo este fator muda conforme o número de voltas completadas na corrida e pode se alterar novamente a qualquer momento se existir uma troca de pneus durante um *Pit Stop*. Este fator costuma ser de conhecimento da área de desenvolvimento de dinâmica veicular de um projeto e pode ser incorporado como variável de entrada, por exemplo, de uma RNA que irá modelar sua relação com a variação de SOC apresentada.

Quanto aos tipos de arquiteturas de uma RNA, as recorrentes (*Recurrent Neural Network*), mais especificamente uma memória de curto prazo longa (*Long Short Term Memory*) podem desempenhar melhores resultados na solução do modelo proposto. A característica de memória da RNA nesta arquitetura pode ser uma vantagem durante as diferentes etapas de uma corrida. Considerar o histórico recente dos dados para estimar o resultado pode ser positivo e ajudar o algoritmo a entender as mudanças de fatores como a intervenção de um carro de segurança ou um piloto que acaba de sair do trânsito, já que os momentos que sucedem estes costumam ter diferentes perfis de consumo e características de descarga de corrente que serão solicitados pelo piloto.

Como o desenvolvimento de novas tecnologias para obtenção de parâmetros de saúde para serem utilizados nos módulos de gerenciamento de baterias, os trabalhos futuros devem, em paralelo, desenvolver novas tecnologias com conhecimento aplicado específico à aplicações práticas de *Motorsports*, como a Fórmula E (Figura 5.1), para melhorar o desempenho dos algoritmos.

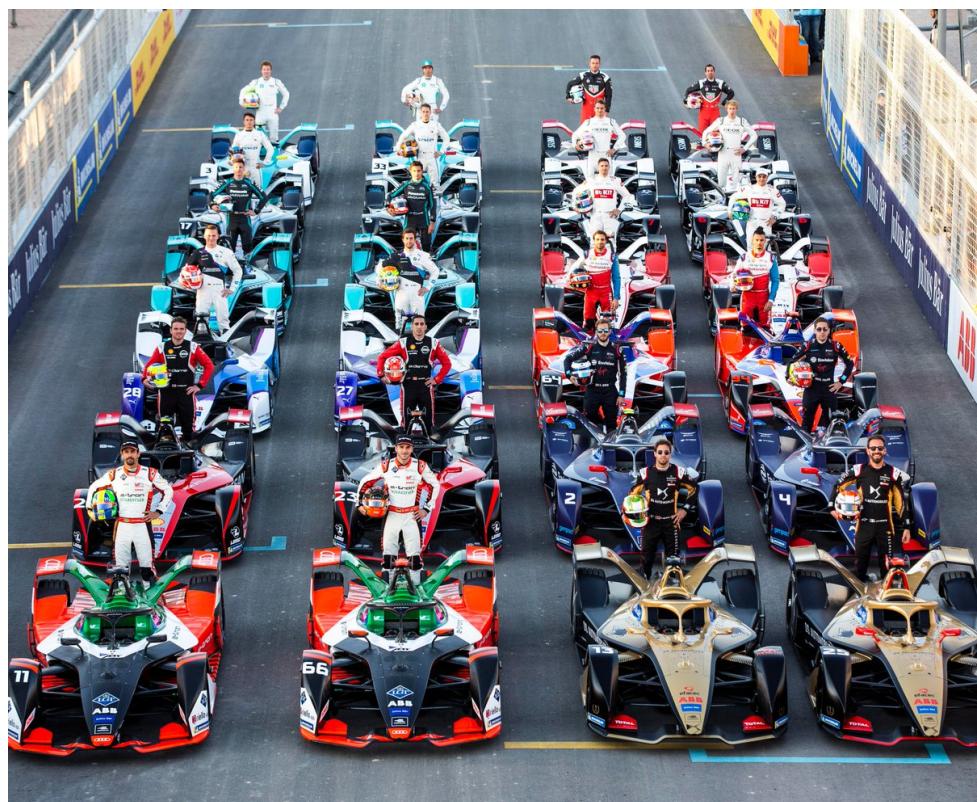


Figura 5.1 – Fórmula E temporada 2019 - 2020

REFERÊNCIAS

- Chang, W.-Y. The state of charge estimating methods for battery: A review. **ISRN Applied Mathematics**, v. 2013, 2013.
- Chen, L.; Xu, R.; Rao, W.; Li, H.; Wang, Y.-P.; Jiang, T. Y. H.-B. Electrochemical model parameter identification of lithium-ion battery with temperature and current dependence. **Int. J. Electrochem. Sci**, v. 14, p. 4124–4143, 2019.
- Chi, Q. C.; Bole Brian ang Hogge, E.; Vazquez, S.; Daigle, M.; Celaya, J.; Weber, A. Battery charge depletion prediction on an electric aircraft. 2013.
- Eddahech, A.; Briat, O.; Bertrand, N.; Deletage, J.-Y.; Vinassa, J.-M. Behavior and state-of-health monitoring of li-ion batteries using impedance spectroscopy and recurrent neural networks. **International Journal of Electrical Power & Energy Systems**, v. 42, n. 1, p. 487–494, 2012.
- Fang, L.; Li, J.; Peng, B. Online estimation and error analysis of both soc and soh of lithium-ion battery based on dekf method. **Energy Procedia**, v. 158, p. 3008–3013, 2019.
- Farfán, J. F.; Palacios, K.; Ulloa, J.; Avilés, A. A hybrid neural network-based technique to improve the flow forecasting of physical and data-driven models: Methodology and case studies in andean watersheds. **Journal of Hydrology: Regional Studies**, v. 27, p. 100652, 2020.
- Guo, L.; Li, J.; Fu, Z. Lithium-ion battery soc estimation and hardware-in-the-loop simulation based on ekf. **Energy Procedia**, v. 158, p. 2599–2604, 2019.
- Hannan, M. A.; Lipu, M. S. H.; Hussain, A.; Saad, M. H.; Ayob, A. Neural network approach for estimating state of charge of lithium-ion battery using backtracking search algorithm. **Ieee Access**, v. 6, p. 10069–10079, 2018.
- He, W.; Pecht, M.; Flynn, D.; Dinmohammadi, F. A physics-based electrochemical model for lithium-ion battery state-of-charge estimation solved by an optimised projection-based method and moving-window filtering. **Energies**, v. 11, n. 8, p. 2120, 2018.
- He, W.; Williard, N.; Chen, C.; Pecht, M. State of charge estimation for li-ion batteries using neural network modeling and unscented kalman filter-based error cancellation. **International Journal of Electrical Power & Energy Systems**, v. 62, p. 783–791, 2014.
- Hosseinzadeh, E.; Marco, J.; Jennings, P. Electrochemical-thermal modelling and optimisation of lithium-ion battery design parameters using analysis of variance. **Energies**, v. 10, n. 9, p. 1278, 2017.
- How, D. N.; Hannan, M.; Lipu, M. H.; Ker, P. J. State of charge estimation for lithium-ion batteries using model-based and data-driven methods: A review. **IEEE Access**, v. 7, p. 136116–136136, 2019.
- Karpatne, A.; Watkins, W.; Read, J.; Kumar, V. Physics-guided neural networks (pgnn): An application in lake temperature modeling. **arXiv preprint arXiv:1710.11431**, 2017.

- Kharazmi, E.; Zhang, Z.; Karniadakis, G. Variational physics-informed neural networks for solving partial differential equations. **arXiv preprint arXiv:1912.00873**, 2019.
- Li, J.; Cheng, Y.; Ai, L.; Jia, M.; Du, S.; Yin, B.; Woo, S.; Zhang, H. 3d simulation on the internal distributed properties of lithium-ion battery with planar tabbed configuration. **Journal of Power Sources**, v. 293, p. 993–1005, 2015.
- Ning, B.; Xu, J.; Cao, B.; Wang, B.; Xu, G. A sliding mode observer soc estimation method based on parameter adaptive battery model. **Energy Procedia**, v. 88, p. 619–626, 2016.
- Nunes, T. M. S.; Oliveira Queiroz, F. F. de; Villanueva, J. M. M.; Macedo, E. C. T. **Modeling and estimation of the state of charge of lithium-ion battery based on artificial neural network**. [S.l.], 2018.
- Raissi, M.; Perdikaris, P.; Karniadakis, G. E. Physics informed deep learning (part i): Data-driven solutions of nonlinear partial differential equations. **arXiv preprint arXiv:1711.10561**, 2017.
- Saxena, A.; Celaya, J. R.; Roychoudhury, I.; Saha, S.; Saha, B.; Goebel, K. Designing data-driven battery prognostic approaches for variable loading profiles: Some lessons learned. In: **European Conference of Prognostics and Health Management Society**. [S.l.: s.n.], 2012. p. 72–732.
- Singh, K. V.; Bansal, H. O.; Singh, D. Hardware-in-the-loop implementation of anfis based adaptive soc estimation of lithium-ion battery for hybrid vehicle applications. **Journal of Energy Storage**, v. 27, p. 101124, 2020.
- Stefanopoulou, A.; Kim, Y. System-level management of rechargeable lithium-ion batteries. In: **Rechargeable Lithium Batteries**. [S.l.]: Elsevier, 2015. p. 281–302.
- Tulsky, A.; Tsai, Y.; Gopaluni, R. B.; Braatz, R. D. State-of-charge estimation in lithium-ion batteries: A particle filter approach. **Journal of Power Sources**, v. 331, p. 208–223, 2016.
- Wang, Y.; Yang, D.; Zhang, X.; Chen, Z. Probability based remaining capacity estimation using data-driven and neural network model. **Journal of Power Sources**, v. 315, p. 199–208, 2016.
- Xing, Y.; He, W.; Pecht, M.; Tsui, K. L. State of charge estimation of lithium-ion batteries using the open-circuit voltage at various ambient temperatures. **Applied Energy**, v. 113, p. 106–115, 2014.
- Yang, D.; Wang, Y.; Pan, R.; Chen, R.; Chen, Z. A neural network based state-of-health estimation of lithium-ion battery in electric vehicles. **Energy Procedia**, v. 105, p. 2059–2064, 2017.
- Zahid, T.; Li, W. A comparative study based on the least square parameter identification method for state of charge estimation of a lifepo4 battery pack using three model-based algorithms for electric vehicles. **Energies**, v. 9, n. 9, p. 720, 2016.
- Zhang, C.; Allafi, W.; Dinh, Q.; Ascencio, P.; Marco, J. Online estimation of battery equivalent circuit model parameters and state of charge using decoupled least squares technique. **Energy**, v. 142, p. 678–688, 2018.

Zhang, L.; Li, K.; Du, D.; Zhu, C.; Zheng, M. A sparse least squares support vector machine used for soc estimation of li-ion batteries. **IFAC-PapersOnLine**, v. 52, n. 11, p. 256–261, 2019.

Zhang, L.; Wang, L.; Lyu, C.; Li, J.; Zheng, J. Non-destructive analysis of degradation mechanisms in cycle-aged graphite/lico₂ batteries. **Energies**, v. 7, n. 10, p. 6282–6305, 2014.

Zhao, R.; Yan, R.; Chen, Z.; Mao, K.; Wang, P.; Gao, R. X. Deep learning and its applications to machine health monitoring. **Mechanical Systems and Signal Processing**, v. 115, p. 213–237, 2019.